

**ANALISIS SENTIMEN APLIKASI KALENDER BALI MENGGUNAKAN
METODE *K-NEAREST NEIGHBOR* (KNN) SERTA *BALANCING DATA*
MENGGUNAKAN *TOMEK LINKS***

SKRIPSI

Diajukan Untuk Memenuhi Salah Satu Syarat
Memperoleh Gelar Sarjana Komputer
Program Studi Informatika



Disusun Oleh:
Ni Made Dina Aprilianti
205314131

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS SANATA DHARMA
YOGYAKARTA**

2024

**SENTIMENT ANALYSIS OF BALI CALENDAR APPLICATION USING
K-NEAREST NEIGHBOR (KNN) METHOD AND DATA BALANCING
USING TOMEK LINKS**

THESIS

Present as Partial Fulfillment of The Requirement
To Obtain The *Sarjana Komputer* Degree
In Informatics Study Program



Created By:

Ni Made Dina Aprilianti

205314131

**FACULTY OF SCIENCE AND TECHNOLOGY
SANATA DHARMA UNIVERSITY
YOGYAKARTA**

2024

LEMBAR PERSETUJUAN PEMBIMBING

SKRIPSI

**ANALISIS SENTIMEN APLIKASI KALENDER BALI MENGGUNAKAN
METODE *K-NEAREST NEIGHBOR* (KNN) SERTA *BALANCING DATA*
MENGGUNAKAN *TOMEK LINKS***

Disusun oleh :

Ni Made Dina Aprilianti

NIM : 205314131

Telah disetujui oleh :

Dosen Pembimbing,

Rosalia Arum Kumalasanti, S.T., M.T.

16 Januari 2023

HALAMAN PENGESAHAN

SKRIPSI

**ANALISIS SENTIMEN APLIKASI KALENDER BALI MENGGUNAKAN
METODE *K-NEAREST NEIGHBOR* (KNN) SERTA *BALANCING DATA*
MENGGUNAKAN *TOMEK LINKS***

Dipersiapkan dan ditulis oleh :

Ni Made Dina Aprilianti

NIM : 205314131

SUSUNAN DEWAN PENGUJI

JABATAN	NAMA LENGKAP	TANDA TANGAN
Ketua	Ir. Robertus Adi Nugroho, M.Eng.	
Sekretaris	Agnes Maria Polina, S.Kom., M.Sc.	
Anggota	Rosalia Arum Kumalasanti, S.T., M.T.	

Yogyakarta, 16 Januari 2024

Fakultas Sains dan Teknologi

Universitas Sanata Dharma

Dekan,

Ir. Drs. Haris Sriwindono, M.Kom, Ph.D.

HALAMAN KEASLIAN KARYA

Saya menyatakan dengan sesungguhnya bahwa skripsi yang saya tulis tidak mengandung atau memuat karya orang lain, kecuali yang telah disebutkan dalam daftar pustaka dengan mengikuti ketentuan sebagaimana layaknya karya ilmiah.

Apabila di kemudian hari ditemukan indikasi plagiarisme dalam naskah ini, saya bersedia menanggung segala sanksi sesuai peraturan perundang-undangan yang berlaku.

Yogyakarta, 5 Desember 2023

Penulis

Ni Made Dina Aprilianti

HALAMAN PERSETUJUAN PUBLIKASI

Yang bertanda tangan di bawah ini, saya mahasiswa Universitas Sanata Dharma :

Nama : Ni Made Dina Aprilianti

NIM : 205314131

Demi pengembangan ilmu pengetahuan, saya memberikan kepada Perpustakaan Universitas Sanata Dharma karya ilmiah saya yang berjudul:

**“Analisis Sentimen Aplikasi Kalender Bali Menggunakan
Metode *K-Nearest Neighbor* (KNN) Serta *Balancing Data*
Menggunakan *Tomek Links*”**

beserta perangkat yang diperlukan (bila ada). Dengan demikian saya memberikan hak kepada Perpustakaan Universitas Sanata Dharma baik untuk menyimpan, mengalihkan dalam bentuk media lain, mengolah dalam bentuk pangkalan data, mendistribusikan secara terbatas, dan mempublikasikannya di internet atau media lain untuk kepentingan akademis tanpa perlu meminta izin dari saya atau memberikan royalti kepada saya selama tetap mencantumkan nama saya sebagai penulis.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di Yogyakarta

Pada tanggal: 16 Januari 2024

Yang menyatakan,

Ni Made Dina Aprilianti

HALAMAN MOTTO

“Life can be heavy, especially if you try to carry it all once, part of growing up and moving into new chapters of your life is about catch or realease. What I mean by that is, knowing what things to keep and what things to realease. You can’t carry all things, all grudges, all updates on your ex, all enviable promotions your school bully got at the bedge fund his uncle started. Decided what is yours to hold and let the rest go.”

(Taylor Swift)

KATA PENGANTAR

Om Swastiastu

Rasa angayu bagia penulis panjatkan kehadapan Ida Sang Hyang Widhi Wasa atas asungkerta wara nugraha-Nya, sehingga penulis dapat menyelesaikan penyusunan tugas akhir yang merupakan salah satu persyaratan mencapai Sarjana Komputer di Universitas Sanata Dharma Yogyakarta.

Penulis dapat menyelesaikan penelitian dan penulisan tugas akhir ini karena adanya dukungan berupa doa, semangat dan motivasi yang penulis dapatkan dari berbagai pihak, oleh karena itu penulis ingin menghanturkan rasa terima kasih sedalam-dalamnya kepada ;

1. Ida Sang Hyang Widhi Wasa yang telah memberikan anugrah dan rahmatnya sehingga penulis dapat menyelesaikan tugas akhir ini dengan baik dan lancar.
2. Ibu Rosalia Arum Kumalasanti, S.T., M.T. selaku dosen pembimbing yang telah membimbing dengan sabar, memberikan motivasi, kritik, saran, pikiran, waktu serta tenaga sehingga penulis dapat menyelesaikan tugas akhir ini dengan baik.
3. Bapak Ir. Drs. Haris Sriwindono, M.Kom, Ph.D., selaku Dekan Fakultas Sains dan Teknologi Universitas Sanata Dharma Yogyakarta.
4. Bapak Dr. Ir. Iwan Binanto, selaku ketua Program Studi Informatika Universitas Sanata Dharma.
5. Ibu Agnes Maria Polina, S.Kom., M.Sc. selaku Dosen Pembimbing Akademik yang selalu membantu saya dari awal hingga akhir perkuliahan.
6. Seluruh dosen yang telah mendidik dan memberikan ilmu pengetahuan

selama penulis menjalani pendidikan di Universitas Sanata Dharma.

7. I Gede Sukadana dan Veronika Erni Utari selaku orang tua penulis, serta Luh Gede Rina Widiyanti selaku saudara penulis yang selalu memberikan dukungan moral, material dan spiritual selama proses penyelesaian tugas akhir.
8. I Komang Gopinda Aditya Saputra, terima kasih atas dukungan, semangat, serta telah menjadi tempat berkeluh kesah, selalu ada dalam suka maupun duka selama proses penyusunan skripsi ini.
9. Oni, Deby, Jeany, Kiki, Gita, Hani, Eli, Dolla, Angel, dan Diva selaku sahabat yang selalu menemani serta memberikan semangat kepada penulis.
10. Teman-teman Informatika 2020 untuk kebersamaan selama menjalani masa perkuliahan.
11. Semua pihak yang secara langsung maupun tidak langsung telah membantu penulis dalam penyelesaian tugas akhir ini.

Penulis menyadari terdapat banyak kekurangan dalam penelitian dan penulisan tugas akhir ini. Penulis mengharapkan saran, kritik dan pendapat dari yang membangun dari pembaca, sehingga tugas akhir ini dapat menjadi lebih baik lagi dikemudian hari. Semoga penelitian ini dapat memberikan manfaat bagi semua pihak.

Om Santi, Santi, Santi Om

Yogyakarta, 5 Desember 2023

Ni Made Dina Aprilianti

ABSTRAK

Perkembangan teknologi telah membawa kemudahan, kecepatan, dan praktisitas dalam mencari dan mendapatkan apa yang dibutuhkan. Kemajuan teknologi memberikan kemudahan pada orang Bali yang berada di luar Pulau Bali, terkhusus bagi yang beragama Hindu untuk mendapatkan kalender Bali. Aplikasi tersebut mempermudah mereka untuk dapat mengetahui hari raya suci yang ada pada hari maupun bulan tertentu. Aplikasi Kalender Bali mendapatkan beragam respon dari penggunanya, baik itu pendapat positif seperti pujian maupun pendapat negatif berupa kritik dan keluhan. Adapun penelitian ini akan melakukan klasifikasi sentimen ke dalam dua jenis yaitu positif dan negatif menggunakan metode *K-Nearest Neighbor* (KNN) untuk menentukan sentimen publik mengenai kepuasan pengguna terhadap aplikasi Kalender Bali. KNN merupakan metode klasifikasi yang mengelompokkan data baru berdasarkan jarak data baru ke beberapa data atau tetangga terdekat. Penelitian ini juga menerapkan metode *Tomek Links* untuk meningkatkan kinerja kode program klasifikasi KNN dalam analisis ulasan aplikasi Kalender Bali. Metode *Tomek Links* digunakan untuk mengatasi ketidakseimbangan data (*imbalance dataset*) dengan cara menurunkan jumlah sampel mayoritas yang posisinya berdekatan dengan sampel minoritas di sekitarnya. Data yang tidak seimbang menyulitkan metode klasifikasi dalam melakukan fungsi generalisasi pada proses *machine learning*. Dalam penelitian juga dilakukan pembagian rentang waktu data menjadi sebelum dan setelah pandemi covid, dikarenakan ulasan negatif memiliki jumlah yang lebih tinggi setelah pembaruan aplikasi di masa pandemi covid. Hasil penelitian pada data sebelum covid didapat bahwa akurasi tertinggi pada metode KNN tanpa atau dengan *Tomek Links* dengan parameter $K=5$ dan $K=3$, masing-masing adalah sebesar 93.7% dan 94.3%. Hasil penelitian pada data setelah covid didapat bahwa akurasi tertinggi pada metode KNN tanpa atau dengan *Tomek Links* dengan parameter $K=9$, masing-masing adalah sebesar 86.0% dan 87.2%. Pada data setelah covid, peningkatan akurasi akibat penggunaan *Tomek Links* bernilai lebih tinggi yakni sebesar 1.2% dibandingkan penggunaan pada data sebelum covid yang hanya menaikkan akurasi sebesar 0.6%. Penelitian ini menunjukkan bahwa metode *Tomek Links* mempengaruhi nilai akurasi yang dilakukan oleh KNN saat data yang digunakan tidak seimbang.

Kata kunci : Kalender Bali, Analisis Sentimen, *K-Nearest Neighbor*, *Imbalance Dataset*, *Tomek Links*

ABSTRACT

Technological developments have brought convenience, speed and practicality in finding and getting what is needed. Technological advances make it easier for Balinese people outside the island of Bali, especially Hindus, to get the Balinese calendar. This application makes it easier for them to find out which holy holidays are on certain days or months. The Bali Calendar application has received various responses from its users, both positive opinions such as praise and negative opinions in the form of criticism and complaints. This research will classify sentiment into two types, namely positive and negative using the K-Nearest Neighbor (KNN) method to determine public sentiment regarding user satisfaction with the Bali Calendar application. KNN is a classification method that groups new data based on the distance of the new data to several data or nearest neighbors. This research also applies the Tomek Links method to improve the performance of the KNN classification program code in analyzing reviews of the Bali Calendar application. The Tomek Links method is used to overcome imbalance dataset by reducing the number of majority samples whose positions are close to the surrounding minority samples. Imbalance dataset makes it difficult for classification methods to carry out generalization functions in the machine learning process. In the research, the data time period was also divided into before and after the Covid pandemic, because negative reviews had a higher number after the application was updated during the Covid pandemic. The results of research on pre-covid data showed that the highest accuracy in the KNN method without or with Tomek Links with parameter $K=5$ and $K=3$ was 93.7% and 94.3%, respectively. The results of research on data after Covid showed that the highest accuracy in the KNN method without or with Tomek Links with parameter $K=9$ was 86.0% and 87.2%, respectively. In post-covid data, the increase in accuracy due to the use of Tomek Links is higher, namely 1.2% compared to use of pre-covid data which only increased accuracy by 0.6%. This research shows that the Tomek Links method affects the accuracy values carried out by KNN when the data used is unbalanced.

Keywords: *Balinese Calendar, Sentiment Analysis, K-Nearest Neighbor, Imbalance Dataset, Tomek Links*

DAFTAR ISI

HALAMAN SAMPUL	i
HALAMAN PERSETUJUAN PEMBIMBING	iii
HALAMAN PENGESAHAN	iv
HALAMAN KEASLIAN KARYA	v
HALAMAN PERSETUJUAN PUBLIKASI.....	vi
HALAMAN MOTTO	vii
KATA PENGANTAR.....	viii
ABSTRAK.....	x
ABSTRACT	xi
DAFTAR ISI.....	xii
DAFTAR TABEL.....	xv
DAFTAR GAMBAR.....	xvi
BAB I PENDAHULUAN	1
1.1. Latar Belakang.....	1
1.2. Rumusan Masalah	4
1.3. Tujuan Penelitian.....	4
1.4. Batasan Masalah	4
1.5. Manfaat Penelitian.....	5
BAB II TINJAUAN PUSTAKA.....	6
2.1 Hasil Publikasi.....	6
2.2 Tinjauan Teoritis	15
2.2.1. Kalender Bali.....	15
2.2.2. <i>Web Scraping</i>	17
2.2.3. Analisis Sentimen.....	17
2.2.4. KNN	18
2.2.5. <i>Text Mining</i>	19
2.2.6. <i>Pre-Processing</i>	19
2.2.6.1 Labeling	19
2.2.6.2 Case Folding dan Cleaning	20
2.2.6.3 Tokenizing.....	20
2.2.6.4 Normalization	20
2.2.6.5 Stemming	21

2.2.6.6	Stopword Removal.....	21
2.2.7.	Pembobotan Kata	22
2.2.8.	<i>Tomek Links</i>	23
2.2.9.	<i>K-Fold Cross Validation</i>	23
2.2.10.	<i>Confusion Matrix</i>	24
2.2.9.1	Akurasi.....	26
2.2.9.2	Presisi.....	26
2.2.9.3	Recall	26
2.2.9.4	F1 Score	26
BAB III	METODOLOGI PENELITIAN	27
3.1	Sumber Data	27
3.2	Gambaran Umum Penelitian	28
3.3	Tahapan Penelitian	29
3.3.1.	Pengumpulan Data	29
3.3.2.	<i>Pre-Processing</i>	31
3.3.2.1	Labeling	32
3.3.2.2	Case Folding dan Cleaning	33
3.3.2.3	Tokenizing.....	34
3.3.2.4	Normalization	35
3.3.2.5	Stemming	36
3.3.2.6	Stopword Removal.....	37
3.3.3.	Pembagian Rentang Waktu Data.....	38
3.3.4.	Pembobotan Kata	40
3.3.5.	Pembagian Data.....	44
3.3.6.	Klasifikasi.....	45
3.3.7.	<i>Balancing Data</i>	49
3.3.8.	Klasifikasi Menggunakan <i>Balanced Dataset</i>	50
3.3.9.	Evaluasi	54
3.3.10.	Skenario Pengujian	59
3.4	Kebutuhan Hardware dan Software.....	60
3.4.1.	Spesifikasi <i>Hardware</i>	60
3.4.2.	Spesifikasi <i>Software</i>	61
BAB IV	IMPLEMENTASI HASIL DAN ANALISIS HASIL	62
4.1	Implementasi Pengumpulan Data.....	62

4.2	Implementasi <i>Pre-processing</i>	65
4.2.1	<i>Labeling</i>	65
4.2.2	<i>Case folding dan Cleaning</i>	66
4.2.3	<i>Tokenizing</i>	70
4.2.4	<i>Normalization</i>	72
4.2.5	<i>Stemming</i>	76
4.2.6	<i>Stopword Removal</i>	78
4.2.7	<i>Cleaning</i>	80
4.3	Implementasi Pembagian Rentang Waktu Data	81
4.4	Implementasi Pembobotan Kata.....	83
4.5	Implementasi Pembagian Data	86
4.6	Implementasi Klasifikasi	89
4.7	Implementasi <i>Balancing</i> Data	96
4.8	Implementasi Klasifikasi menggunakan <i>Balanced</i> Dataset	100
BAB V KESIMPULAN DAN SARAN		106
5.1.	Kesimpulan.....	106
5.2.	Saran	107
DAFTAR PUSTAKA		108

DAFTAR TABEL

Tabel 2. 1 Tabel referensi penelitian.....	6
Tabel 2. 2 Confusion Matrix	25
Tabel 3. 1 Sampel Ulasan dari Aplikasi Kalender Bali	30
Tabel 3. 2 Contoh Penerapan Labeling.....	32
Tabel 3. 3 Contoh Penerapan Case Folding dan Cleaning.....	33
Tabel 3. 4 Contoh Penerapan Tokenizing	35
Tabel 3. 5 Contoh Penerapan Normalization	36
Tabel 3. 6 Contoh Penerapan Stemming.....	37
Tabel 3. 7 Contoh Penerapan Stopword Removal	38
Tabel 3. 8 Contoh Penerapan Pembagian Rentang Waktu Data	39
Tabel 3. 9 Contoh Perhitungan TF dan DF	40
Tabel 3. 10 Contoh Perhitungan Bobot IDF	41
Tabel 3. 11 Contoh Perhitungan Bobot TF-IDF	42
Tabel 3. 12 Contoh Penerapan K-Fold Crossvalidation	44
Tabel 3. 13 Euclidean Distance untuk Fold 1 Data Tidak Seimbang	46
Tabel 3. 14 Euclidean Distance untuk Fold 2 Data Tidak Seimbang	47
Tabel 3. 15 Euclidean Distance untuk Fold 3 Data Tidak Seimbang	48
Tabel 3. 16 Data sebelum dan setelah balancing data	49
Tabel 3. 17 Euclidean Distance untuk Fold 1 Data Seimbang	51
Tabel 3. 18 Euclidean Distance untuk Fold 2 Data Seimbang	52
Tabel 3. 19 Euclidean Distance untuk Fold 3 Data Seimbang	53
Tabel 3. 20 Confusion Matrix untuk Fold 1 Data Tidak Seimbang.....	54
Tabel 3. 21 Confusion Matrix untuk Fold 2 Data Tidak Seimbang.....	54
Tabel 3. 22 Confusion Matrix untuk Fold 3 Data Tidak Seimbang.....	54
Tabel 3. 23 Confusion Matrix Total Data Tidak Seimbang	54
Tabel 3. 24 Confusion Matrix untuk Fold 1 Data Seimbang.....	56
Tabel 3. 25 Confusion Matrix untuk Fold 2 Data Seimbang.....	56
Tabel 3. 26 Confusion Matrix untuk Fold 3 Data Seimbang.....	56
Tabel 3. 27 Confusion Matrix Total Data Seimbang	56
Tabel 3. 28 Skenario Pengujian	59
Tabel 4. 1 Contoh Hasil Labeling	66
Tabel 4. 2 Contoh Hasil Case Folding dan Cleaning	67
Tabel 4. 3 Rincian Index Terhapus	68
Tabel 4. 4 Contoh Hasil Cleaning Row	70
Tabel 4. 5 Contoh Hasil Tokenizing	71
Tabel 4. 6 Contoh Isi Kamus Normalization	72
Tabel 4. 7 Contoh Hasil Normalization	74
Tabel 4. 8 Contoh Hasil Stemming.....	78
Tabel 4. 9 Contoh Hasil Stopword Removal	80

DAFTAR GAMBAR

Gambar 2. 1	Logo Aplikasi Kalender Bali	16
Gambar 2. 2	Rating Aplikasi Kalender Bali	16
Gambar 2. 3	Ilustrasi Balancing Data dengan Tomek Links Undersampling	23
Gambar 3. 1	Contoh Ulasan Aplikasi Kalender Bali	27
Gambar 3. 2	Diagram Alir Penelitian	28
Gambar 3. 3	Diagram Alir Tahap Pengumpulan Data	29
Gambar 3. 4	Diagram Alir Tahap Pre-Processing	31
Gambar 3. 5	Diagram Alir Tahap Labeling	32
Gambar 3. 6	Diagram Alir Tahap Case Folding dan Cleaning	33
Gambar 3. 7	Diagram Alir Tahap Tokenizing	34
Gambar 3. 8	Diagram Alir Tahap Normalization	35
Gambar 3. 9	Diagram Alir Tahap Stemming	36
Gambar 3. 10	Diagram Alir Tahap Stopword Removal	37
Gambar 3. 11	Diagram Alir Pembagian Rentang Waktu Data	38
Gambar 3. 12	Diagram Alir Pembobotan Kata TF-IDF	40
Gambar 3. 13	Diagram Alir K-Nearest Neighbor	45
Gambar 3. 14	Ilustrasi distribusi data sebelum dan setelah Tomek Link	49
Gambar 3. 15	Perbandingan Hasil Evaluasi	58
Gambar 4. 1	Source Code Pengumpulan Data	62
Gambar 4. 2	Hasil Pengumpulan Data	63
Gambar 4. 3	Source Code Pemilihan Kolom	64
Gambar 4. 4	Contoh Dataset Setelah Menggunakan Kolom Terpilih	64
Gambar 4. 5	Source Code Labeling	65
Gambar 4. 6	Source Code Case Folding dan Cleaning	66
Gambar 4. 7	Source Code Cleaning Row	68
Gambar 4. 8	Source Code Tokenizing	71
Gambar 4. 9	Source Code Normalization Menggunakan Kamus	73
Gambar 4. 10	Source Code Normalization Menggabungkan Token Berspasi	75
Gambar 4. 11	Source Code Normalization Menggabungkan Token Tanpa Spasi	76
Gambar 4. 12	Source Code Stemming	77
Gambar 4. 13	Source Code Stopword Removal	79
Gambar 4. 14	Source Code Cleaning List Kosong	80
Gambar 4. 15	Source Code Pembagian Rentang Waktu Data	81
Gambar 4. 16	Distribusi Data Sebelum dan Setelah Pandemi Covid	82
Gambar 4. 17	Distribusi Sentimen Data Sebelum dan Setelah Pandemi Covid..	83
Gambar 4. 18	Source Code Pembobotan Kata	84
Gambar 4. 19	Contoh Pembobotan Kata Untuk Data Sebelum Covid	84
Gambar 4. 20	Contoh Pembobotan Kata Untuk Data Setelah Covid	85
Gambar 4. 21	Wordcloud Sebelum Covid	85
Gambar 4. 22	Wordcloud Setelah Covid	86
Gambar 4. 23	Source Code Pembagian Data	87
Gambar 4. 24	Distribusi Pembagian Data Untuk Data Sebelum Pandemi Covid	88
Gambar 4. 25	Distribusi Pembagian Data Untuk Data Setelah Pandemi Covid .	89

Gambar 4. 26	Source Code Klasifikasi KNN	90
Gambar 4. 27	Perbandingan Akurasi Pada Data Sebelum Pandemi Covid.....	91
Gambar 4. 28	Perbandingan Presisi Pada Data Sebelum Pandemi Covid.....	92
Gambar 4. 29	Perbandingan Recall Pada Data Sebelum Pandemi Covid	92
Gambar 4. 30	Perbandingan F1 Score Pada Data Sebelum Pandemi Covid	93
Gambar 4. 31	Perbandingan Akurasi Pada Data Setelah Pandemi Covid	94
Gambar 4. 32	Perbandingan Presisi Pada Data Setelah Pandemi Covid.....	94
Gambar 4. 33	Perbandingan Recall Pada Data Setelah Pandemi Covid	95
Gambar 4. 34	Perbandingan F1 Score Pada Data Setelah Pandemi Covid	95
Gambar 4. 35	Source Code Tomek Links	96
Gambar 4. 36	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 3 .	97
Gambar 4. 37	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 5 .	97
Gambar 4. 38	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 7 .	98
Gambar 4. 39	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 9 .	98
Gambar 4. 40	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 3 .	99
Gambar 4. 41	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 5 .	99
Gambar 4. 42	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 7 .	99
Gambar 4. 43	Perbandingan Distribusi Data Hasil Tomek Links Pada k-fold 9	100
Gambar 4. 44	Perbandingan Akurasi KNN dan Tomek Links Pada Data Sebelum Pandemi Covid	101
Gambar 4. 45	Perbandingan Presisi KNN dan Tomek Links Pada Data Sebelum Pandemi Covid	101
Gambar 4. 46	Perbandingan Recall KNN dan Tomek Links Pada Data Sebelum Pandemi Covid	102
Gambar 4. 47	Perbandingan F1 Score KNN dan Tomek Links Pada Data Sebelum Pandemi Covid	102
Gambar 4. 48	Perbandingan Akurasi KNN dan Tomek Links Pada Data Setelah Pandemi Covid	103
Gambar 4. 49	Perbandingan Presisi KNN dan Tomek Links Pada Data Setelah Pandemi Covid	104
Gambar 4. 50	Perbandingan Recall KNN dan Tomek Links Pada Data Setelah Pandemi Covid	104
Gambar 4. 51	Perbandingan F1 Score KNN dan Tomek Links Pada Data Setelah Pandemi Covid	105

BAB I

PENDAHULUAN

Bab ini membahas mengenai latar belakang, rumusan masalah, tujuan penelitian, manfaat penelitian, Batasan masalah serta sistematika penulisan yang digunakan.

1.1. Latar Belakang

Perkembangan teknologi saat ini telah mengubah cara orang mendapatkan akses terhadap berbagai kebutuhan mereka. Hal ini telah membawa kemudahan, kecepatan, dan praktisitas dalam mencari dan mendapatkan apa yang dibutuhkan. Sebelum adanya teknologi yang maju, orang Bali yang berada di luar Pulau Bali cukup mengalami kesulitan dalam memperoleh kalender Bali. Mereka harus mencari toko atau penjual yang menyediakan kalender Bali, yang mungkin terbatas di luar Pulau Bali. Proses ini tentunya memakan waktu, tenaga, dan biaya yang tidak efisien.

Dikutip dari data Badan Pusat Statistik (BPS) proporsi individu yang menggunakan internet di berbagai provinsi di Indonesia menunjukkan peningkatan yang cukup signifikan. Tahun 2017, sekitar 32,34% individu di Indonesia menggunakan internet, angka tersebut meningkat menjadi 39,90% di tahun 2018, kemudian mencapai angka 47,69% di tahun 2019 (Badan Pusat Statistik, 2019). Peningkatan yang konsisten dari tahun ke tahun ini menandakan bahwa setiap tahun, pengguna internet di berbagai wilayah provinsi di Indonesia semakin bertambah jumlahnya. Kemudahan mengakses internet tersebut membantu semua orang khususnya yang beragama Hindu menjadi mudah, cepat dan praktis untuk mendapatkan kalender Bali melalui aplikasi Kalender Bali yang tersedia di *Google*

Play Store. Aplikasi Kalender Bali merupakan penyempurnaan dan penyederhanaan dari aplikasi wargabali yang dilengkapi dengan fitur untuk melakukan pencarian unsur-unsur wariga dalam Kalender Bali seperti pencarian otonan, perjodohan, hari raya Hindu, Ala Ayuning, Pengaturan Dewasa dan mengelola *reminder* (Alitmd, 2021).

Aplikasi Kalender Bali memberikan manfaat besar bagi orang Bali yang berada di luar Pulau Bali. Mereka dapat tetap terhubung dengan tradisi dan budaya Bali melalui kalender Bali yang akurat dan terkini karena dapat dengan mudah melihat tanggal-tanggal penting, hari raya, dan perayaan lainnya dalam kalender Bali. Majunya teknologi telah memberikan akses yang mudah, cepat, dan praktis bagi semua orang untuk mendapatkan kalender Bali. Hal tersebut merupakan contoh nyata bagaimana teknologi mempengaruhi cara orang memenuhi kebutuhan mereka dan mempertahankan identitas budaya di era digital saat ini.

Aplikasi Kalender Bali mendapatkan beragam respons dari penggunanya, baik itu pendapat positif seperti pujian maupun pendapat negatif yang berupa keluhan yang dipublikasikan di berbagai *website*, salah satunya adalah *Google Play Store*. Komentar pada platform *Google Play Store* berfokus pada pengembangan pendekatan analisis sentimen yang dirancang khusus untuk *Google Play Store*. Pendekatan ini bertujuan untuk menganalisis dan memahami pendapat, evaluasi, dan sentimen pengguna terhadap aplikasi yang tersedia di *Google Play Store*. Melalui analisis sentimen ini, diharapkan akan muncul pemahaman yang lebih mendalam tentang opini dan preferensi pengguna yang dapat meningkatkan kualitas dan kepuasan pengguna di platform *Google Play Store*.

Pada penelitian Riza Adrianti Supono dan Muhammad Azis Suprayogi (2021), dilakukan penelitian terhadap teks helpdesk dengan menggunakan metode KNN dengan metode pembobotan TF-IDF menghasilkan akurasi sebesar 90.04%. Penelitian ini mengungkapkan bahwa penggunaan jumlah fitur dan nilai k pada KNN berpengaruh terhadap klasifikasi. Maka dari itu perlu dilakukan pemilihan persentase fitur dan nilai k yang tepat untuk menghasilkan akurasi yang maksimal.

Pada penelitian yang dilakukan oleh Puji Astuti dan Nuzuliarini Nuris (2022) terhadap ulasan aplikasi Peduli Lindungi dari *Google Play Store* menggunakan metode KNN, menghasilkan akurasi sebesar 81,74%. Dalam penelitian tersebut peneliti mengungkapkan bahwa penggunaan metode KNN tanpa kombinasi dengan metode apapun telah menghasilkan performa yang cukup baik untuk melakukan klasifikasi.

Penelitian selanjutnya masih meneliti ulasan yang sama yaitu ulasan untuk aplikasi Peduli Lindungi, namun pada penelitian ini nama aplikasi sudah diperbaharui dengan nama Satu Sehat *Mobile*. Pada penelitian dengan data tersebut, Ida Ayu Mirah Cahya Dewi, I Komang Dharmandra dan Ni Wayan Setiasih (2023) melakukan klasifikasi menggunakan metode KNN dan *Tomek Links*. Didapatkan bahwa klasifikasi KNN tanpa *Tomek Links* menghasilkan akurasi sebesar 74,91%, hasil tersebut kurang optimal jika dibandingkan dengan klasifikasi menggunakan KNN dan *Tomek Links* yang mendapat akurasi sebesar 76,40%.

Berdasarkan uraian diatas, penelitian ini akan melakukan klasifikasi sentimen ke dalam 2 jenis yaitu positif dan negatif menggunakan metode *K-Nearest Neighbor* (KNN) untuk klasifikasi ulasan aplikasi Kalender Bali di *platform Google Play Store* serta menggunakan metode *Tomek Links* untuk

menangani ketidakseimbangan data (*imbalanced dataset*). Dengan pengaplikasian penelitian ini, diharapkan dapat menjadi salah satu solusi penilaian masyarakat terhadap aplikasi Kalender Bali melalui analisis sentimen yang dihasilkan.

1.2. Rumusan Masalah

Rumusan masalah yang diperoleh dari latar belakang adalah sebagai berikut:

1. Bagaimana mendapatkan akurasi yang optimal dalam melakukan klasifikasi ulasan aplikasi *mobile* Kalender Bali dengan menggunakan metode KNN
2. Bagaimana pengaruh penerapan teknik *Tomek Links* terhadap akurasi klasifikasi menggunakan metode KNN pada dataset yang mengalami *imbalanced dataset*?

1.3. Tujuan Penelitian

Tujuan penelitian yang diperoleh dari rumusan masalah adalah sebagai berikut:

1. Memperoleh akurasi yang optimal dalam melakukan klasifikasi ulasan aplikasi *mobile* Kalender Bali dengan menggunakan metode KNN
2. Menerapkan teknik *Tomek Links* terhadap akurasi klasifikasi menggunakan metode KNN pada dataset yang mengalami *imbalanced dataset*

1.4. Batasan Masalah

Agar penelitian ini dapat dilakukan lebih fokus, sempurna, dan mendalam maka penulis memandang permasalahan penelitian yang diangkat perlu dibatasi variabelnya. Oleh sebab itu, penulis membatasi diri hanya berkaitan dengan :

1. Ulasan mengenai Aplikasi Kalender Bali dari *Google Play Store*

2. Ulasan yang dianalisis merupakan ulasan dalam Bahasa Indonesia
3. Ulasan hanya akan dikelompokkan menjadi sentimen positif dan negatif
4. Nilai k (*neighbor*) yang digunakan untuk penelitian adalah 3, 7, 5, dan 9
5. Nilai k untuk *k-Fold Cross Validation* adalah 3, 7, 5, dan 9

1.5. Manfaat Penelitian

1. Bagi Peneliti

Mengaplikasikan ilmu-ilmu akademis yang didapat selama perkuliahan untuk klasifikasi teks terhadap ulasan Google Play Store mengenai penggunaan aplikasi *mobile* Kalender Bali menggunakan metode KNN dan *Tomek Links*

2. Bagi Universitas

Mengukur tingkat kemampuan mahasiswa dalam menerapkan ilmu akademis maupun non-akademis di lingkungan masyarakat

3. Bagi Pembaca

- a. Menambah wawasan pembaca mengenai metode KNN dalam melakukan analisis sentimen terhadap data ulasan *Google Play Store*
- b. Memberikan panduan kepada pembaca untuk menerapkan metode KNN menggunakan bahasa pemrograman *Python*

BAB II

TINJAUAN PUSTAKA

Bab ini membahas mengenai hasil publikasi yang memuat uraian tentang hasil penelitian yang pernah dilakukan sebelumnya oleh peneliti lain yang berkaitan dengan penelitian yang dilakukan serta membahas mengenai tinjauan teoritis yang memuat konsep dan prinsip dasar untuk memecahkan masalah penelitian.

2.1 Hasil Publikasi

Hasil publikasi membahas mengenai hasil penelitian sebelumnya yang termuat di dalam jurnal-jurnal yang isinya berkaitan dengan penelitian. Mengenai jurnal-jurnal yang terkait, dapat di lihat pada tabel 2.1.

Tabel 2. 1 Tabel referensi penelitian

No	Penelitian	Data	Metode	Hasil
1	Perbandingan Metode TF-ABS dan TF-IDF Pada Klasifikasi Teks <i>Helpdesk</i> Menggunakan <i>K-Nearest Neighbor</i> (Supono and Suprayogi, 2021)	Dataset : tiket <i>helpdesk</i> 2019-2020 Jumlah data : 10.537 tiket	Klasifikasi : KNN Pembobotan :: TF-ABS dan TF-IDF	<u>Akurasi</u> KNN + TF-ABS : 90,04% KNN + TF-IDF : 72,11%

No	Penelitian	Data	Metode	Hasil
2	Penerapan Algoritma KNN Pada Analisis Sentimen <i>Review</i> Aplikasi Peduli Lindungi (Astuti and Nuris, 2022)	Dataset : Ulasan aplikasi peduli lindungi dari <i>google play store</i> Positif : 100 Negatif : 100	Klasifikasi : KNN	<u>Akurasi</u> : 81,74% <u>AUC</u> : 0,861
3	Analisis Sentiment Pada Ulasan Aplikasi Indodax di <i>Google Play Store</i> Menggunakan Metode <i>Support Vector Machine</i> (Wahyudi and Kusumawardana, 2021)	Dataset : Ulasan aplikasi indodax di <i>google play store</i> Positif : 565 Negatif : 573	Klasifikasi : <i>Support Vector Machine (SVM)</i> Labeling : pelabelan data disesuaikan dengan <i>rating</i> yang diterima aplikasi di <i>google play store</i> , dimana <i>rating</i> dengan bintang 1 sampai 3 berlabel negatif dan <i>rating</i> 4 dan 5 berlabel positif Pembobotan :	<u>Akurasi</u> : 85% <u>Presisi</u> : 94% <u>Recall</u> : 78% <u>F1 Score</u> : 85%

No	Penelitian	Data	Metode	Hasil
			TF-IDF	
4	<i>Comparative Study of Sentiment Analysis with Product Reviews Using Machine Learning and Lexicon-Based Approaches</i> (Veluchamy <i>et al.</i> , 2018)	Dataset : 1000 ulasan produk amazon Positif : 82% Negatif : 18%	Klasifikasi : Logistic Regression (LR), Support Vector Machine (SVM), dan Gradient Boosting Labeling : menggunakan <i>score/rating</i> produk amazon dimana <i>score</i> 1,2,3 berlabel negatif dan <i>score</i> 4,5 berlabel positif Pembobotan :: TF-IDF	<u>Akurasi :</u> SVM : 89% Gradient Boosting : 87% LR : 90% <u>Presisi :</u> SVM : 90% Gradient Boosting : 88% LR : 91% <u>Recall :</u> SVM : 98% Gradient Boosting : 98% LR : 97% <u>F1 Score :</u> SVM : 94% Gradient Boosting : 92% LR : 94%
5	Analisis Sentimen Review Aplikasi Satu Sehat Mobile Menggunakan Model Sampling Tomek Links	Dataset : <i>Review</i> pengguna aplikasi satu sehat <i>mobile</i> di halaman <i>play store</i>	Klasifikasi : Random Forest (RF), Neural Network, KNN, dan SVM	<u>Akurasi :</u> RF : 79,760% RF + Tomek Links : 80,405% Neural Network : 74,484

No	Penelitian	Data	Metode	Hasil
	(Dewi, Dharmendra and Setiasih, 2023)	Positif : 2174 Negatif : 8440	<i>Balancing Data</i> : <i>Tomek Links</i> Labeling : nilai bintang 1 sampai 2 berlabel negatif dan bintang 3 sampai 5 berlabel positif Pembobotan : TF-IDF	<i>Neural Network + Tomek Links</i> : 74,706% KNN : 74,916% KNN + Tomek Links : 76,401% SVM : 80,528% SVM + Tomek Links : 81,017% <u>Presisi :</u> RF : 79,601% RF + Tomek Links : 81,004% <i>Neural Network</i> : 74,027% <i>Neural Network + Tomek Links</i> : 74,162% KNN : 74,385% KNN + Tomek Links : 75,256% SVM : 81,306% SVM + Tomek Links : 81,951% <u>Recall :</u> RF : 79,760% RF + Tomek Links : 80,405%

No	Penelitian	Data	Metode	Hasil
				Neural Network : 74,484% Neural Network + Tomek Links : 74,706% KNN : 74,916% KNN + Tomek Links : 76,401% SVM : 80,528% SVM + Tomek Links : 81,017% <u>F1 Score :</u> RF : 77,991% RF + Tomek Links : 78,243% Neural Network : 74,221% Neural Network + Tomek Links : 74,384% KNN : 74,599% KNN + Tomek Links : 75,321% SVM : 78,394% SVM + Tomek Links : 78,872%
6	Analisis Perbandingan Algoritma KNN, Gaussian Naïve	Dataset : LCMS Tanaman Keladi Tikus	Klasifikasi : KNN, Gaussian Naive Bayes, dan	<u>Akurasi :</u> KNN : 0,9850 KNN + Tomek Links : 0,9851

No	Penelitian	Data	Metode	Hasil
	<i>Bayes, Random Forest</i> Untuk Data Tidak Seimbang Dan Data Yang Diseimbangkan Dengan Metode <i>Tomek Links Undersampling</i> Pada Dataset LCMS Tanaman Keladi Tikus (Aprilianti <i>et al.</i> , 2023)	Jumlah Data: 663.228	Random Forest(RF) <i>Balancing data:</i> Tomek Links	Gaussian Naive Bayes : 0,9852 Gaussian Naive Bayes + Tomeks Links : 0,9852 RF : 0,9901 RF + Tomek Links : 0,9999 <u>Presisi :</u> KNN : 0,4400 KNN + Tomek Links : 0,4444 Gaussian Naive Bayes : 0,0000 Gaussian Naive Bayes + Tomeks Links : 0,0000 RF : 0,9956 RF + Tomek Links : 1,0000 <u>Recall :</u> KNN : 0,0111 KNN + Tomek Links : 0,0184 Gaussian Naive Bayes : 0,0000 Gaussian Naive Bayes + Tomeks Links : 0,0000

No	Penelitian	Data	Metode	Hasil
				RF : 0,3439 RF + Tomek Links : 0,9994 <u>F1 Score :</u> KNN : 0,0217 KNN + Tomek Links : 0,0355 Gaussian Naive Bayes : 0,0000 Gaussian Naive Bayes + Tomeks Links : 0,0000 RF : 0,5112 RF + Tomek Links : 0,9997
7	Peningkatan Performa Analisis Sentimen dengan <i>Resampling</i> dan <i>Hyperparameter</i> pada Ulasan Aplikasi BNI Mobile (Wijanarto and Brilianti, 2020)	Dataset : ulasan pengguna aplikasi BNI Mobile Banking di <i>google play store</i> Positif : 84% Negatif : 16%	Klasifikasi : Naive Bayes <i>Balancing Data</i> : ROS, SMOTE, Adasysn, SMOTE-NC B1-SMOTE, RUS, <i>Nearmiss,</i> <i>Tomek Links,</i> <i>Edited Nearest</i> <i>Neighbours</i> (ENN), Repeted <i>Edidted</i>	<u>Akurasi :</u> Naive Bayes : 88,50% Naive Bayes + ROS : 93,40% Naive Bayes + Adasysn : 93,25% Naive Bayes + SMOTE-NC : 89,68% Naive Bayes + B1-SMOTE : 87,99% Naive Bayes + RUS : 93,71%

No	Penelitian	Data	Metode	Hasil
			<i>Nearest Neighbours (RENN)</i> <i>Allknn, One Sided Selection, Neighbourhood Cleaning Rule (NCL), SMOTEENN, SMOTETomek</i>	<i>Naive Bayes + Nearmiss :</i> 94,04% <i>Naive Bayes + Tomek Links :</i> 92,68% <i>Naive Bayes + ENN :</i> 95,92% <i>Naive Bayes + RENN :</i> 98,22% <i>Naive Bayes + Allknn :</i> 96,30% <i>Naive Bayes + One Sided Selection :</i> 92,68% <i>Naive Bayes + NCL:</i> 94,35% <i>Naive Bayes + SMOTEEEN :</i> 98,89% <i>Naive Bayes + SMOTETomek :</i> 93,58%
8	Analisis Sentimen dari Aplikasi Shopee Indonesia Menggunakan Metode <i>Recurrent Neural</i>	Dataset : ulasan pengguna aplikasi shopee dari <i>google play store</i>	Klasifikasi : Recurrent Neural Network (RNN)	<u>Akurasi :</u> RNN : 0,745% RNN + SMOTE + Tomek Links : 0,800 <u>Presisi :</u>

No	Penelitian	Data	Metode	Hasil
	<i>Network</i> (Utami, 2022)	Positif : 800 Negatif : 200	<i>Balancing Data</i> : kombinasi SMOTE dan Tomek Links Pembobotan : TF-IDF	RNN : 0,791 RNN + SMOTE + Tomek Links : 0,841 <u>Recall :</u> RNN : 0,925 RNN + SMOTE + Tomek Links : 0,925 <u>F1 Score :</u> RNN : 0,853 RNN + SMOTE + Tomek Links : 0,881 <u>Spesifisitas :</u> RNN : 0,025 RNN + SMOTE + Tomek Links : 0,300
9	Klasifikasi Sentimen Data Tidak Seimbang Menggunakan Algoritma SMOTE Dan <i>K-Nearest Neighbor</i> Pada Ulasan	Dataset : Ulasan aplikasi peduli lindungi dari <i>google play store</i> Positif : 250 Negatif : 750	Klasifikasi : KNN <i>Balancing Data</i> : SMOTE Labeling : manual oleh tiga annotator	<u>Akurasi :</u> KNN : 91% KNN + SMOTE : 97,66% <u>Presisi :</u> KNN : 94,44% KNN + SMOTE : 96,91%

No	Penelitian	Data	Metode	Hasil
	Pengguna Aplikasi Pedulilindungi (Barus, 2022)		Pembobotan : TF-IDF	<u>F1 Score:</u> KNN : 79,99% KNN + SMOTE : 97,81%
10	<i>Machine learning-based maternal health risk prediction model for IoMT framework</i> (Mondal et al., 2023)	Dataset : data kesehatan dan faktor risiko yang terkait dengan kehamilan	Klasifikasi : Random Forest (RF), Decision Tree (DT), Support Vector Machine (SVM), KNN, and Logistic Regression (LR).	<u>Akurasi</u> <u>klasifikasi:</u> RF : 86,27% DT : 86,27% KNN : 75,54% SVM : 68,62% LR : 65,86% <u>Akurasi klasifikasi</u> <u>+ SMOTE :</u> RF : 90,16% DT : 88,52% KNN : 77,04% SVM : 67,21% LR : 65,57%

2.2 Tinjauan Teoritis

Tinjauan teoritis menjelaskan pendekatan teori yang akan digunakan untuk menjelaskan persoalan yang diangkat dalam penelitian.

2.2.1. Kalender Bali


Kalender Saka Bali didasari oleh penanggalan konvensi yang sifatnya tidak mutlak astronomis seperti kalender Hijriyah, tetapi tidak pula seperti kalender Jawa, dimana kalender Bali ini kira-kira ada di antara keduanya. Kalender Saka Bali merupakan penanggalan berdasarkan posisi matahari dan bulan. Aplikasi Kalender

Bali merupakan kalender saka Bali yang memberikan informasi mengenai penanggalan hari raya umat Hindu. Aplikasi ini memberikan kemudahan kepada umat beragama Hindu khususnya dalam mencari unsur-unsur wariga dalam Kalender Saka Bali seperti pencarian otonan, perjodohan, hari raya Hindu, Ala Ayuning, Pengaturan Dewasa dan mengelola *reminder* (Alitmd, 2021).



Gambar 2. 1 Logo Aplikasi Kalender Bali

Gambar 2.1 merupakan logo dari aplikasi Kalender Bali yang ada pada platform *Google Play Store*. *Google Play Store* merupakan layanan digital milik Google yang didalamnya memuat layanan berupa toko online untuk memasarkan produk berupa aplikasi, permainan (*game*), film, acara TV, buku dan konten lainnya. Penggunaanya cukup variatif dalam memberikan ulasan dari positif hingga negatif, lengkap dengan nilai atau *score* aplikasi dari 1-5 bintang. Semakin besar score yang diberikan, maka semakin positif ulasan yang diberikan oleh penggunaanya. Rata-rata score atau *rating* aplikasi Kalender Bali sendiri mencapai 4,6 bintang pada platform tersebut. Grafik distribusi *score* untuk *rating* dapat dilihat pada gambar 2.2.



Gambar 2. 2 Rating Aplikasi Kalender Bali

2.2.2. *Web Scraping*

Website atau situs web merupakan serangkaian halaman web yang memiliki tema yang sama dan saling berhubungan yang berisikan kumpulan informasi yang disediakan secara perorangan, kelompok, atau organisasi. *Website* ditempatkan pada sebuah server *web* yang dapat diakses melalui jaringan seperti internet, ataupun jaringan wilayah lokal (LAN) melalui alamat internet yang dikenal dengan URL (Uniform Resources Locator) (Erawan, 2015). *Web scraping* adalah proses proses pengambilan data melalui program yang berinteraksi dengan API (*Application Programming Interface*) dari sebuah server *web*. Umumnya akan berupa halaman web dalam bahasa markup seperti HTML maupun file lainnya yang menyusun halaman *web* (Mitchell, 2018).

Google-play-scraper merupakan salah satu alat API yang digunakan untuk *web scraping*. *Google-play-scraper* adalah modul yang menyediakan antarmuka untuk mengakses data dari *Google Play Store*. Modul ini memberikan akses kepada pengguna untuk mengambil informasi seperti detail aplikasi, ulasan, dan lainnya (Python, 2023).

2.2.3. *Analisis Sentimen*

Analisis sentimen atau penambangan opini merupakan bidang studi yang menganalisis opini, sentimen, penilaian, sikap, dan emosi orang terhadap entitas dan atributnya yang diungkapkan dalam teks tertulis (Liu, 2015). Analisis sentimen merupakan topik penelitian yang aktif dibawah Natural Language Proccessing. Analisis sentimen memiliki tujuan untuk membangun sebuah metode yang dapat diimplementasikan menjadi sebuah alat untuk mengekstraksi informasi subjektif berupa sentimen atau opini dalam sebuah data text. Umumnya sentimen terbagi ke

dalam tiga nilai yakni positif, netral, serta negatif. Dalam beberapa kasus kecenderungan penelitian tentang analisis sentimen lebih berfokus pada pendapat yang menyatakan suatu sentimen memiliki nilai positif atau negatif.

2.2.4. KNN

K-Nearest Neighbor (KNN) merupakan algoritma pencarian jarak terdekat diantara data yang akan dievaluasi dengan k tetangga (*neighbors*) terdekatnya di dalam data pelatihan. Pada umumnya nilai k yang digunakan merupakan angka ganjil, misalnya $k = 1, 3, 5, 7, 9$ dan seterusnya. KNN masuk ke dalam metode *supervised learning* yang merupakan bagian dari *machine learning*. *Supervised learning* menggunakan data yang telah memiliki label untuk melatih model serta memprediksi output. Keunggulan KNN adalah tahan terhadap data latih dengan banyak *noise* serta data dengan jumlah yang tinggi/besar, namun kekurangan dari KNN adalah masih perlu menentukan nilai k dan memilih atribut yang terbaik (Cholil *et al.*, 2021).

Menurut Helilintar *et al.* (2013), urutan proses kerja KNN adalah sebagai berikut:

1. Menentukan parameter k (jumlah tetangga paling dekat).
2. Menghitung kuadrat jarak euclidean (euclidean distance) masing-masing obyek terhadap data sampel yang diberikan.

$$d_i = \sqrt{\sum_{i=1}^p (x_{2i} - x_{1i})^2} \quad (2.1)$$

Keterangan :

- d = jarak
- p = dimensi data
- x_1 = sampel data

- x_2 = data uji/*testing*
- i = variable data

2.2.5. *Text Mining*

Text Mining merupakan metodologi dan alat untuk menemukan (*discovering*), memvisualisasikan (*presenting*), serta mengevaluasi pengetahuan dokumen atau data berupa teks. *Text mining* ini bertujuan untuk menemukan pola data dan informasi yang bermanfaat untuk tujuan tertentu sehingga dapat dilakukan analisis keterhubungan antar dokumen tersebut. *Text mining* juga dapat digunakan untuk mendapat pengetahuan antar domain atau secara umum untuk mengambil keputusan operasional dan startegis (Westergaard *et al.*, 2018).

2.2.6. *Pre-Processing*

Dalam *text mining* biasanya terdapat beberapa data berupa dokumen yang tidak terstruktur. Berdasarkan ketidakaturan struktur data tersebut maka diperlukan tahap *text preprocessing* untuk mempersiapkan teks yang terstruktur dan siap untuk dianalisa. *Text Preprocessing* dilakukan dengan tahapan sebagai berikut:

2.2.6.1 *Labeling*

Labeling merupakan proses melabeli data yang akan digunakan sebagai sentimen positif dan sentimen negatif. Labeling dapat dilakukan berdasarkan score ulasan dalam platform *Google Play Store* (Wahyudi and Kusumawardana, 2021). Ulasan yang menerima *score* 1, 2, atau 3 akan diberi label negatif, sedangkan ulasan yang menerima *score* 4 atau 5 akan diberi label positif. Pemberian label dengan score juga dapat dilakukan dalam platform selain *Google Play Store*, yang masih menggunakan score misalnya dari platform Amazon (Veluchamy *et al.*, 2018).

2.2.6.2 Case Folding dan Cleaning

Case folding merupakan pengubahan huruf dalam dokumen menjadi huruf kecil (*lower-case*). *Case folding* bertujuan untuk mendapatkan huruf yang seragam agar teridentifikasi sebagai kata atau teks yang sama. *Cleaning* merupakan proses menghilangkan semua karakter teks yang mengandung tanda baca, angka, URL, kode ASCII, dan emoji. *Cleaning* bertujuan untuk mengurangi *noise* dalam ulasan pengguna sehingga didapatkan ulasan yang bersih dan dapat dengan mudah dipahami (Alhaqq, Putra and Ruldeviyani, 2022).

2.2.6.3 Tokenizing

Tokenizing merupakan proses membagi teks menjadi bagian-bagian kata yang terstruktur sehingga dapat dihitung jumlah frekuensi kata yang muncul (Alhaqq, Putra and Ruldeviyani, 2022). Pemotongan kata atau pemisahan kalimat dilakukan berdasarkan spasi yang memisahkan teks. Potongan kata tersebut biasa disebut dengan token. *Tokenizing* dilakukan untuk mempermudah proses yang selanjutnya seperti *stemming* dan *stopword removal*.

2.2.6.4 Normalization

Normalization merupakan proses mengubah kata tidak baku menjadi kata baku menggunakan kamus baku yang ada untuk menghilangkan duplikasi kata dengan arti yang sama (Iwandini, Triayudi and Soepriyono, 2023). Dalam penelitian ini memuat *normalization* untuk Bahasa Indonesia tidak baku, Bahasa Bali, serta Bahasa Inggris yang di normalisasi menjadi Bahasa Indonesia baku. Kamus baku yang digunakan untuk *normalization* adalah Kamus Besar Bahasa Indonesia (KBBI) serta Kamus Bahasa Bali-Bahasa Indonesia (Denes *et al.*, 1997).

Proses *normalization* Bahasa Inggris sendiri menggunakan bantuan Google *Translete* untuk menerjemahkan kata ke dalam Bahasa Indonesia.

2.2.6.5 Stemming

Stemming atau *lemmatize* merupakan tahap mengembalikan kata-kata dengan akhiran atau awalan ke bentuk dasarnya (Barus, 2022). Tujuan dari stemming adalah untuk menghapus afiks (imbuhan) dari kata-kata sehingga hanya sisa kata dasar yang relevan yang tetap. Dengan melakukan *stemming*, kata-kata yang memiliki akar yang sama akan dianggap sebagai bentuk yang sama, sehingga dapat membantu dalam pengelompokan dan analisis teks. Pustaka yang umum digunakan untuk proses *stemming* Bahasa Indonesia adalah *stemmer* sastrawi. Sastrawi bekerja dengan menggunakan algoritma pemotongan kata (*stemming*) untuk bahasa Indonesia. Dengan menggunakan *stemmer* Sastrawi, kata-kata yang memiliki akar kata yang sama akan diubah menjadi bentuk dasar yang seragam. Sastrawi memiliki aturan dan kamus internal untuk memahami struktur bahasa Indonesia dan menerapkan pemotongan kata dengan benar. Proses ini membantu menyederhanakan analisis teks, meningkatkan akurasi pencarian, dan mendukung berbagai aplikasi pemrosesan bahasa alami (Python, 2016).

2.2.6.6 Stopword Removal

Stopword merupakan kata atau data yang tidak berguna, sehingga *stopward removal* merupakan penghapusan kata-kata yang kurang bermakna, kurang penting ataupun tidak dibutuhkan seperti “di”, “ke”, “dari”, “pada” dan lain sebagainya (Supono and Suprayogi, 2021). *Stopword* dihapuskan saat pemrosesan teks karena dianggap kurang informatif. Adapun salah satu pustaka pemrograman yang biasa digunakan untuk melakukan proses ini adalah NLTK (*Natural Language Toolkit*)

Stopword List Bahasa Indonesia. NLTK merupakan pustaka Python yang umum digunakan untuk pemrosesan bahasa alami (NLP) . NLTK menyediakan daftar stopwords dalam berbagai bahasa, termasuk bahasa Indonesia. Daftar ini mencakup kata-kata seperti "yang", "sebuah", "tidak", yang sering muncul dalam teks tetapi tidak memberikan kontribusi signifikan. Setelah menghilangkan stopwords maka diakhir proses ini akan didapatkan kata-kata yang lebih bermakna dan relevan untuk analisis teks.

2.2.7. Pembobotan Kata

Pembobotan merupakan metode untuk mengubah input data menjadi suatu fitur vektor. Salah satu teknik pembobotan kata adalah *Term Frequency – Inverse Document Frequency* (TF-IDF) yang merupakan statistik numerik yang merepresentasikan pentingnya kata dalam sebuah dokumen (Purbo, 2019). Rumus yang digunakan adalah:

$$TFIDF = TF \times IDF = TF \times \log \frac{|D|}{DF} \quad (2.2)$$


Keterangan :

- TF : *term frequency* atau banyaknya kemunculan kata
- DF : *document frequency* atau jumlah dokumen di mana kata/istilah tersebut muncul.
- $|D|$: jumlah seluruh dokumen

Dalam hal ini, nilai TF yang tinggi akan membuat nilai TF-IDF menjadi tinggi yang berarti kata tersebut penting. Namun, jika nilai DF tinggi maka akan membuat nilai TF-IDF rendah.

2.2.8. Tomek Links

Tomek Links merupakan salah satu teknik *undersampling* yaitu mengurangi sampel secara acak dari kelas mayoritas (Utami, 2022). Semisal data di dalam kelas positif memiliki jumlah yang lebih tinggi dibandingkan data di dalam kelas negatif, maka sampel yang akan dikurangi jumlahnya adalah sampel di kelas positif. Pengurangan jumlah sampel tersebut dilakukan untuk menangani ketidakseimbangan data (*unbalanced dataset*) antara kelas positif dan kelas negatif.



Gambar 2. 3 Ilustrasi *Balancing Data dengan Tomek Links Undersampling*

Pada gambar 2.3, *Tomek Links* melakukan penyeimbangan data dengan mengurangi jumlah sampel mayoritas yang posisinya berdekatan dengan sampel minoritas yang berada di sekitarnya (Dewi, Dharmendra and Setiasih, 2023). Tujuan dari *Tomek Links* adalah mendapatkan data yang seimbang (*balanced dataset*) untuk kemudian digunakan dalam proses klasifikasi.

2.2.9. K-Fold Cross Validation

Cross Validation merupakan teknik validasi model untuk menilai hasil analisis statistic yang akan menggeneralisasi set data independent. Tujuan utamanya adalah melihat keakuratan model prediktif (Purbo, 2019). *K-fold cross validation* sendiri merupakan salah satu teknik yang ada dalam *cross validation*. "K" di dalam istilah "*k-fold*" sendiri merujuk pada jumlah kelompok (*fold*) atau potongan data

yang dibagi selama proses *cross validation*. Proses *k-Fold Cross Validation* melibatkan pembagian dataset menjadi "k" bagian yang sebanding. Selanjutnya, model dilatih dan dievaluasi sebanyak "k" kali, di mana pada setiap iterasi, salah satu dari "k" fold digunakan sebagai data uji (*testing*) sementara sisanya digunakan sebagai data latih (*training*). Proses ini berulang hingga setiap *fold* telah digunakan sebagai data uji sebanyak satu kali. Teknik ini akan memberikan perkiraan kinerja model yang lebih stabil dengan membagi dataset menjadi beberapa *fold* kemudian menghitung rata-rata hasil dari evaluasi.

Dalam *k-Fold Cross Validation* sendiri terdapat *random state* yang digunakan untuk mengontrol pengacakan dalam pembagian data menjadi *fold*. Nilai *random state* yang biasa digunakan adalah 42, untuk membantu menjaga konsistensi dan reproduktibilitas hasil percobaan, memastikan bahwa pembagian *fold* tetap sama setiap kali eksperimen diulang (Aprilianti *et al.*, 2023). Misalnya, dalam *k-Fold Cross Validation* dengan $k=3$ dan *random state* = 42, dataset akan dibagi menjadi 3 bagian yang sama. Proses pelatihan dan evaluasi akan dilakukan sebanyak 3 kali, di mana setiap kali salah satu bagian digunakan sebagai data uji dan yang lainnya sebagai data latih.

2.2.10. Confusion Matrix

Confusion Matrix merupakan metode evaluasi yang dapat digunakan untuk menghitung kinerja atau tingkat kebenaran dari proses klasifikasi (Purbo, 2019). Confusion matrix terdiri dari bagian utama, yang masing-masing mewakili skenario yang berbeda dalam hasil klasifikasi yaitu *True Positive*, *True Negative*, *False Positive* dan *False Negative*.

Tabel 2. 2 *Confusion Matrix*

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	<i>True Positive</i>	<i>False Negative</i>
	<i>Negative</i>	<i>False Positive</i>	<i>True Negative</i>

Berikut merupakan penjelasan untuk tabel 2.2:

- *True Positive* (TP) merupakan jumlah observasi yang benar-benar termasuk dalam kelas positif. Artinya hasil prediksi model dan kelas aktual model sama yakni kelas positif.
- *True Negative* (TN) merupakan jumlah observasi yang benar-benar termasuk dalam kelas negatif. Artinya hasil prediksi model dan kelas aktual model sama yakni kelas negatif.
- *False Positive* (FP) merupakan jumlah observasi yang seharusnya tidak termasuk dalam kelas positif, tetapi diprediksi sebagai kelas positif. Artinya hasil prediksi model adalah kelas negatif, namun ternyata kelas aktual model menunjukkan kelas positif.
- *False Negative* (FN) merupakan jumlah observasi yang seharusnya termasuk dalam kelas positif, tetapi diprediksi sebagai kelas negatif. Artinya hasil prediksi model adalah kelas positif, namun ternyata kelas aktual model menunjukkan kelas negatif.

Confusion Matrix menjadi metode yang paling sering digunakan untuk menghitung tingkat akurasi, presisi, *recall*, dan *F1 score* untuk *data mining*.

2.2.9.1 Akurasi

Akurasi merupakan rata-rata aritmetika dari presisi dan *inverse* presisi (oleh Bias) serta merupakan rata-rata aritmetika dari recall dan *inverse* recall (oleh Pravelansi). Perhitungan akurasi dapat dilihat pada persamaan 2.3.

$$Akurasi = \frac{TP+TN}{TP+FP+TN+FN} \quad (2.3)$$

2.2.9.2 Presisi

Presisi atau nilai prediktif positif merupakan potongan dari *instance* yang diambil yang relevan. Presisi akan merepresentasikan tingkat ketepatan antara informasi yang diminta oleh pengguna dengan jawaban yang diberikan oleh sistem. Perhitungan akurasi dapat dilihat pada persamaan 2.4.

$$Presisi = \frac{TP}{TP+FP} \quad (2.4)$$

2.2.9.3 Recall

Recall atau sensitivitas merupakan potongan contoh yang relevan yang diambil. *Recall* akan merepresentasikan tingkat keberhasilan sistem dalam menemukan kembali sebuah informasi. Perhitungan akurasi dapat dilihat pada persamaan 2.5.

$$Recall = \frac{TP}{TP+FN} \quad (2.5)$$

2.2.9.4 F1 Score

F1 score merupakan metrik evaluasi yang mencerminkan keseimbangan antara presisi dan *recall* (sensitivitas). Dalam hal ini, *F1 score* memberikan gambaran mengenai seberapa baik model dalam mengklasifikasikan semua sentimen ulasan baik itu ulasan positif maupun ulasan negatif secara akurat.

$$F1\ score = 2 \times \frac{recall \times presisi}{recall + presisi} \quad (2.6)$$


BAB III

METODOLOGI PENELITIAN

Bab ini membahas mengenai sumber data, gambaran umum penelitian, tahap-tahap penelitian, skenario pengujian, kebutuhan *hardware* dan *software*, desain *user interface*, serta jadwal penelitian.

3.1 Sumber Data


Penelitian ini akan menggunakan data ulasan aplikasi Kalender Bali yang diperoleh dari *Google Play Store*. Pengambilan data dilakukan dengan menggunakan teknik *web scrapping*, dimana *package* yang digunakan adalah *package google-play-scraper* dari Bahasa pemrograman *python*. Data ulasan yang diambil nantinya merupakan ulasan yang menggunakan Bahasa Indonesia. Contoh ulasan yang ada di *Google Play Store* dapat dilihat pada gambar 3.1.



Gambar 3. 1 Contoh Ulasan Aplikasi Kalender Bali

3.2 Gambaran Umum Penelitian

Berikut merupakan alur dari penelitian ini :



Gambar 3.2 Diagram Alir Penelitian

Berdasarkan diagram alir penelitian pada gambar 3.2, langkah-langkah pada penelitian dimulai dengan mengumpulkan data ulasan melalui website *Google Play Store*. Data yang telah didapatkan tersebut kemudian dilakukan *pre-processing*, meliputi *labeling*, *case folding* dan *cleaning*, *tokenizing*, *normalization*, *stemming* serta *stopword removal*. Tahap *pre-processing* ini dilakukan agar data ulasan menjadi data yang siap digunakan untuk tahap yang selanjutnya. Tahap


selanjutnya adalah pembobotan kata dengan menggunakan teknik *Term Frequency – Inverse Document Frequency* (TF-IDF) yang membentuk vektor antara dokumen dan kata. Setelah itu data akan dibagi menjadi data *training* dan data *testing* menggunakan *k-Fold Cross Validation* untuk kemudian digunakan dalam proses klasifikasi menggunakan metode KNN serta klasifikasi menggunakan KNN dan *Tomek Links*. Proses akhir adalah melakukan evaluasi dengan *confusion matrix* yang terdiri dari akurasi, presisi dan *recall*.

3.3 Tahapan Penelitian

Tahapan penelitian memuat langkah-langkah yang ditempuh dalam melakukan penelitian, meliputi :

3.3.1. Pengumpulan Data

Berikut merupakan alur dari tahap pengumpulan data :



Gambar 3. 3 Diagram Alir Tahap Pengumpulan Data

Berdasarkan diagram alir penelitian pada gambar 3.3, hal pertama yang perlu melakukan instalasi package *google-play-scraper* terlebih dahulu. Selanjutnya *import library reviews_all* dari *google-play-scraper* serta *import library pandas*. Pengumpulan data kemudian dilakukan menggunakan teknik *webscrapping* dengan package *google-play-scraper*. Data yang diambil merupakan

data ulasan mengenai aplikasi Kalender Bali. Data ulasan yang diperoleh kemudian disimpan ke dalam dokumen berbentuk csv.


Dari proses pengumpulan data tersebut diperoleh data ulasan mengenai aplikasi Kalender Bali menggunakan Bahasa Indonesia. Data mentah atau data yang belum diolah tersebut diambil dari tanggal 4 Agustus 2013 hingga tanggal 28 Juni 2023 dengan jumlah ulasan yang didapat adalah 5617 ulasan. Penelitian ini akan melakukan penghapusan beberapa data karena terdapat ulasan yang hanya memuat aksara bali dan emoji. Sampel ulasan dari aplikasi Kalender Bali dapat dilihat pada tabel 3.1.

Tabel 3. 1 Sampel Ulasan dari Aplikasi Kalender Bali

	<i>userName</i>	<i>content</i>	<i>score</i>	<i>at</i>
1	Raja Rimba	Non muslim kalender...sdh kuhapus..	1	17/6/2023 3:57:44 AM
2	I Dewa Ketut Nova Widi Utama	Bagus dan tahu kapan tanggal merah sama ada alarm tri sandya	5	30/5/2023 6:48:43 AM
3	I Wayan Gunawan	Sangat bermanfaat	5	7/8/2022 5:34:20 AM
4	Ajik Mika	Trimakasih. Slu diingatkan dgn kewajiban trisandya Aplikasinya orang HINDU tulen	5	2/5/2022 9:25:37 PM
5	Kristin Nurhayati	Sangat membantu sekali ..untuk menggigat weton	5	3/5/2021 8:59:42 AM
6	Aditya Gen	Duh alarm kalender tdk berfungsi. Sudah lbh baik dihp	2	17/12/2020 10:45:42 PM

3.3.2. *Pre-Processing*


Pada tahap ini akan dijelaskan proses yang dilakukan untuk mengubah data ulasan yang masih mentah menjadi data ulasan yang bersih dan siap untuk digunakan pada proses selanjutnya atau yang dikenal dengan tahap *pre-processing*. Tahap ini terdiri dari *labeling*, *case folding* dan *cleaning*, *tokenizing*, *normalization*, *stemming*, serta *stopword removal*. Alur dari tahap *pre-processing* dapat dilihat pada gambar 3.4.



Gambar 3. 4 Diagram Alir Tahap *Pre-Processing*

3.3.2.1 Labeling

Berikut merupakan alur dari proses *labeling* :



Gambar 3. 5 Diagram Alir Tahap *Labeling*


Proses *labeling* merupakan proses pemberian label sentimen pada data ulasan. Dapat dilihat dari gambar 3.5, bahwa pada penelitian ini melakukan *labeling* berdasarkan nilai *score* ulasan. Ulasan dengan *score* lebih dari 3 akan diberi label sentimen positif sedangkan ulasan dengan *score* kurang dari sama dengan 3 diberi label sentimen negatif. Hasil akhir dari proses ini akan diperoleh data yang telah bersentimen positif dan negatif. Contoh penerapan proses *labeling* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.2.

Tabel 3. 2 Contoh Penerapan *Labeling*

Data Ulasan Mentah	Score	Label Sentimen
Non muslim kalender...sdh kuhapus..	1	Negatif
Bagus dan tahu kapan tanggal merah sama ada alarm tri sandya	5	Positif
Sangat bermanfaat	5	Positif
Trimakasih. Slu diingatkan dgn kewajiban trisandya Aplikasinya orang HINDU tulen	5	Positif
Sangat membantu sekali ..untuk menggigat weton	5	Positif
Duh alarm kalender tdk berfungsi. Sudah lbh baik dihps	2	Negatif

3.3.2.2 Case Folding dan Cleaning

Berikut merupakan alur dari proses *case folding* dan *cleaning* :



Gambar 3. 6 Diagram Alir Tahap *Case Folding* dan *Cleaning*

Berdasarkan gambar 3.6, proses *case folding* dan *cleaning* dilakukan dengan membaca setiap kata dan karakter pada dataset kemudian mengubah setiap huruf dalam dokumen menjadi huruf kecil atau lebih dikenal dengan *lowercasing*. Selanjutnya menghilangkan karakter selain huruf yang tidak diperlukan seperti tanda baca, angka serta simbol yang tidak memiliki relevansi dengan dokumen. Hasil akhir dari tahap ini adalah data ulasan yang seragam menggunakan huruf kecil dan bersih dari karakter yang tidak diperlukan. Contoh penerapan proses *case folding* dan *cleaning* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.3.


Tabel 3. 3 Contoh Penerapan *Case Folding* dan *Cleaning*

Data Ulasan (Mentah)	Hasil Proses <i>Case Folding</i> dan <i>Cleaning</i>
Non muslim kalender...sdh kuhapus..	non muslim kalender sdh kuhapus
Bagus dan tahu kapan tanggal merah sama ada alarm tri sandya	bagus dan tahu kapan tanggal merah sama ada alarm tri sandya
Sangat bermanfaat	sangat bermanfaat

Data Ulasan (Mentah)	Hasil Proses <i>Case Folding dan Cleaning</i>
Trimakasih. Slu diingatkan dgn kewajiban trisandya Aplikasinya orang HINDU tulen	trimakasih slu diingatkan dgn kewajiban trisandya aplikasinya orang hindu tulen
Sangat membantu sekali ..untuk menggigat weton	sangat membantu sekali untuk menggigat weton
Duh alarm kalender tdk berfungsi. Sudah lbh baik dihps	duh alarm kalender tdk berfungsi sudah lbh baik dihps

3.3.2.3 Tokenizing

Berikut merupakan alur dari proses *tokenizing* :



Gambar 3. 7 Diagram Alir Tahap *Tokenizing*


Berdasarkan gambar 3.7, proses *tokenizing* dilakukan dengan mengambil data ulasan dari hasil proses sebelumnya kemudian membaca setiap kata pada dataset dan melakukan pemotongan kata atau memisahkan kalimat menjadi kata. Hasil akhir dari tahap ini adalah token atau potongan kata yang dipisahkan dengan tanda koma (,). Contoh penerapan proses *tokenizing* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.4.

Tabel 3. 4 Contoh Penerapan *Tokenizing*

Hasil Proses Sebelumnya (<i>Case Folding</i> dan <i>Cleaning</i>)	Hasil Proses <i>Tokenizing</i>
non muslim kalendersdh kuhapus	[non, muslim, kalender, sdh, kuhapus]
bagus dan tahu kapan tanggal merah sama ada alarm tri sandya	[bagus, dan, tahu, kapan, tanggal, merah, sama, ada, alarm, tri, sandya]
sangat bermanfaat	[sangat, bermanfaat]
trimakasih slu diingatkan dgn kewajiban trisandya aplikasinya orang hindu tulen	[trimakasih, slu, diingatkan, dgn, kewajiban, trisandya, aplikasinya, orang, hindu, tulen]
sangat membantu sekali untuk menggigat weton	[sangat, membantu, sekali, untuk, menggigat, weton]
duh alarm kalender tdk berfungsi sudah lbh baik dihps	[duh, alarm, kalender, tdk, berfungsi, sudah, lbh, baik, dihps]

3.3.2.4 Normalization

Berikut merupakan alur dari proses *normalization* :

Gambar 3. 8 Diagram Alir Tahap *Normalization*

Berdasarkan gambar 3.8, proses *normalization* dilakukan dengan mengambil data ulasan dari hasil proses sebelumnya kemudian membaca setiap kata pada dataset dan melakukan proses pernormalisasian terhadap kata berlebihan dan kata singkatan dengan cara mengganti kata agar sesuai kaidah dalam kamus Kamus Besar Bahasa Indonesia (KBBI). Normalisasi ini akan mengubah semua kata yang memiliki penggunaan huruf berlebih dan kata singkatan menjadi kata


baku. Hasil akhir dari tahap *normalization* adalah kata yang telah baku sesuai dengan KBBI. Contoh penerapan proses *normalization* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.5.

Tabel 3. 5 Contoh Penerapan *Normalization*

Hasil Proses Sebelumnya (<i>Tokenizing</i>)	Hasil Proses <i>Normalization</i>
[non, muslim, kalendersdh, kuhapus]	[non, muslim, kalender, sudah, kuhapus]
[bagus, dan, tahu, kapan, tanggal, merah, sama, ada, alarm, tri, sandya]	[bagus, dan, tahu, kapan, tanggal, merah, sama, ada, alarm, trisandia]
[sangat, bermanfaat]	[sangat, bermanfaat]
[trimakasih, slu, diingatkan, dgn, kewajiban, trisandya, aplikasinya, orang, hindu, tulen]	[terima, kasih, selalu, diingatkan, dengan, kewajiban, trisandia, aplikasinya, orang, hindu, tulen]
[sangat, membantu, sekali, untuk, menggigat, weton]	[sangat, membantu, sekali, untuk, mengingat, weton]
[duh, alarm, kalender, tdk, berfungsi, sudah, lbh, baik, dihps]	[duh, alarm, kalender, tidak, berfungsi, sudah, lebih, baik, dihapus]

3.3.2.5 Stemming

Berikut merupakan alur dari proses *stemming* :



Gambar 3. 9 Diagram Alir Tahap *Stemming*


Berdasarkan gambar 3.9, proses *stemming* dilakukan dengan mengambil data ulasan dari hasil proses sebelumnya kemudian membaca setiap kata pada dataset dan menghapus imbuhan dari setiap kata agar menjadi kata dasar. Proses *stemming* ini dibantu dengan *stemmer* Bahasa Indonesia dari package *sastrawi*. Hasil akhir dari proses ini adalah ulasan yang berisi kata dasar saja. Contoh penerapan proses *stemming* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.6.

Tabel 3. 6 Contoh Penerapan *Stemming*

Hasil Proses Sebelumnya (<i>Normalization</i>)	Hasil Proses <i>Stemming</i>
[non, muslim, kalender, sudah, kuhapus]	[non, muslim, kalender, sudah, hapus]
[bagus, tanggal, merah, alarm, trisandia]	[bagus, tanggal, merah, alarm, trisandia]
[bermanfaat]	[manfaat]
[terima, kasih, kewajiban, trisandia aplikasinya, orang, hindu, tulen]	[terima, kasih, wajib, trisandia, aplikasi, orang, hindu, tulen]
[membantu, weton]	[bantu, weton]
[duh, alarm, kalender, tidak, berfungsi, lebih, baik, hapus]	[duh, alarm, kalender, tidak, fungsi, sudah, lebih, baik, hapus]

3.3.2.6 Stopword Removal

Berikut merupakan alur dari proses *stopword removal* :



Gambar 3. 10 Diagram Alir Tahap *Stopword Removal*


Berdasarkan gambar 3.10, proses *stopword removal* dilakukan dengan mengambil data ulasan dari hasil proses sebelumnya kemudian membaca setiap kata pada dataset kemudian melakukan penghapusan kata-kata sambung yang tidak memiliki banyak arti. Penghapusan kata ini didasari dengan penggunaan kamus *Stopword List* Bahasa Indonesia. Hasil akhir dari proses ini adalah ulasan tanpa kata yang termasuk dalam kamus *stopword*. Contoh penerapan proses *stopword removal* pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.7.

Tabel 3. 7 Contoh Penerapan *Stopword Removal*

Hasil Proses Sebelumnya (<i>Normalization</i>)	Hasil Proses <i>Stopword Removal</i>
[non, muslim, kalender, sudah, hapus]	[non, muslim, kalender, hapus]
[bagus, tanggal, merah, alarm, trisandia]	[bagus, tanggal, merah, alarm, trisandia]
[manfaat]	[manfaat]
[terima, kasih, wajib, trisandia, aplikasi, orang, hindu, tulen]	[terima, kasih, kewajiban, trisandia, aplikasinya, orang, hindu, tulen]
[bantu, weton]	[bantu, weton]
[duh, alarm, kalender, tidak, fungsi, sudah, lebih, baik, hapus]	[alarm, kalender, fungsi, baik, hapus]

3.3.3. Pembagian Rentang Waktu Data

Berikut merupakan alur dari tahap pembagian rentang waktu data :



Gambar 3. 11 Diagram Alir Pembagian Rentang Waktu Data


Berdasarkan gambar 3.11, proses pembagian rentang waktu data cukup sederhana. Mula-mula data hasil *pre-processing* dibaca kemudian dilakukan pembagian rentang waktu data menjadi sebelum dan setelah covid. Pembagian rentang waktu data ini dilakukan karena ada indikasi ulasan negatif yang lebih tinggi setelah pembaruan aplikasi di masa pandemi covid. Dalam hal ini, data yang termasuk dalam rentang waktu data sebelum covid merupakan ulasan yang diunggah dari tanggal 1 Agustus 2013 hingga 29 Februari 2020 sedangkan data yang termasuk dalam rentang waktu data setelah covid merupakan ulasan yang diunggah dari tanggal 2 Maret 2020 hingga 28 Juni 2023. Contoh penerapan proses pembagian rentang waktu data pada ulasan aplikasi Kalender Bali dapat dilihat pada tabel 3.8.

Tabel 3. 8 Contoh Penerapan Pembagian Rentang Waktu Data

at	Hasil Pre-Processing	Rentang Waktu Data
17/6/2023 3:57:44 AM	[non, muslim, kalender, hapus]	Setelah covid
30/5/2023 6:48:43 AM	[bagus, tanggal, merah, alarm, trisandia]	Setelah covid
7/8/2022 5:34:20 AM	[manfaat]	Setelah covid
2/5/2022 9:25:37 PM	[terima, kasih, kewajiban, trisandia, aplikasinya, orang, hindu, tulen]	Setelah covid
3/5/2021 8:59:42 AM	[bantu, weton]	Setelah covid
17/12/2020 10:45:42 PM	[alarm, kalender, fungsi, baik, hapus]	Setelah covid

3.3.4. Pembobotan Kata

Berikut merupakan alur dari tahap pembobotan kata :



Gambar 3. 12 Diagram Alir Pembobotan Kata TF-IDF

Pembobotan kata merupakan proses memberi bobot pada setiap kata, dimana pada penelitian ini, teknik yang digunakan untuk pembobotan kata adalah *Term Frequency – Inverse Document Frequency* (TF-IDF). Dapat dilihat pada gambar 3.12, data mula-mula dibaca lalu dilakukan penghitungan nilai TF dan DF, selanjutnya menghitung bobot IDF lalu terakhir menghitung bobot TF-IDF menggunakan persamaan 2.1. Adapun hasil TF-IDF ini nantinya akan digunakan untuk proses klasifikasi. Contoh penerapan pembobotan kata ulasan aplikasi Kalender Bali yang termasuk rentang waktu data setelah covid dapat dilihat pada tabel 3.9 hingga tabel 3.11.

Tabel 3. 9 Contoh Perhitungan TF dan DF

Term	TF						DF
	D1	D2	D3	D4	D5	D6	
non	1	0	0	0	0	0	1

Term	TF						DF
	D1	D2	D3	D4	D5	D6	
muslim	1	0	0	0	0	0	1
kalender	1	0	0	0	0	1	2
hapus	1	0	0	0	0	1	2
bagus	0	1	0	0	0	0	1
tanggal	0	1	0	0	0	0	1
merah	0	1	0	0	0	0	1
alarm	0	1	0	0	0	1	2
trisanadia	0	1	0	1	0	0	2
manfaat	0	0	1	0	0	0	1
terima	0	0	0	1	0	0	1
kasih	0	0	0	1	0	0	1
wajib	0	0	0	1	0	0	1
aplikasi	0	0	0	1	0	0	1
orang	0	0	0	1	0	0	1
hindu	0	0	0	1	0	0	1
tulen	0	0	0	1	0	0	1
bantu	0	0	0	0	1	0	1
weton	0	0	0	0	1	0	1
fungsi	0	0	0	0	0	1	1
baik	0	0	0	0	0	1	1

Tabel 3. 10 Contoh Perhitungan Bobot IDF

Term	TF						DF	IDF (Log N/DF)
	D1	D2	D3	D4	D5	D6		
non	1	0	0	0	0	0	1	0,778
muslim	1	0	0	0	0	0	1	0,778
kalender	1	0	0	0	0	1	2	0,477
hapus	1	0	0	0	0	1	2	0,477
bagus	0	1	0	0	0	0	1	0,778

Term	TF						DF	IDF (Log N/DF)
	D1	D2	D3	D4	D5	D6		
tanggal	0	1	0	0	0	0	1	0,778
merah	0	1	0	0	0	0	1	0,778
alarm	0	1	0	0	0	1	2	0,477
trisandia	0	1	0	1	0	0	2	0,477
manfaat	0	0	1	0	0	0	1	0,778
terima	0	0	0	1	0	0	1	0,778
kasih	0	0	0	1	0	0	1	0,778
wajib	0	0	0	1	0	0	1	0,778
aplikasi	0	0	0	1	0	0	1	0,778
orang	0	0	0	1	0	0	1	0,778
hindu	0	0	0	1	0	0	1	0,778
tulen	0	0	0	1	0	0	1	0,778
bantu	0	0	0	0	1	0	1	0,778
weton	0	0	0	0	1	0	1	0,778
fungsi	0	0	0	0	0	1	1	0,778
baik	0	0	0	0	0	1	1	0,778

Tabel 3. 11 Contoh Perhitungan Bobot TF-IDF

Term	IDF	TF- IDF					
		D1	D2	D3	D4	D5	D6
non	0,778	0,778	0	0	0	0	0
muslim	0,778	0,778	0	0	0	0	0
kalender	0,477	0,477	0	0	0	0	0,477
hapus	0,477	0,477	0	0	0	0	0,477
bagus	0,778	0	0,778	0	0	0	0
tanggal	0,778	0	0,778	0	0	0	0
merah	0,778	0	0,778	0	0	0	0
alarm	0,477	0	0,477	0	0	0	0,477
trisandia	0,477	0	0,477	0	0,477	0	0

Term	IDF	TF- IDF					
		D1	D2	D3	D4	D5	D6
manfaat	0,778	0	0	0,778	0	0	0
terima	0,778	0	0	0	0,778	0	0
kasih	0,778	0	0	0	0,778	0	0
wajib	0,778	0	0	0	0,778	0	0
aplikasi	0,778	0	0	0	0,778	0	0
orang	0,778	0	0	0	0,778	0	0
hindu	0,778	0	0	0	0,778	0	0
tulen	0,778	0	0	0	0,778	0	0
bantu	0,778	0	0	0	0	0,778	0
weton	0,778	0	0	0	0	0,778	0
fungsi	0,778	0	0	0	0	0	0,778
baik	0,778	0	0	0	0	0	0,778

Adapun tujuan perhitungan pada tabel diatas yaitu :

(1) Tabel 3.8 Contoh Perhitungan TF & DF

Perhitungan TF bertujuan untuk mencari *term* atau kata yang cocok terhadap dokumen sedangkan perhitungan DF bertujuan untuk mencari jumlah dokumen yang mengandung *term*.

(2) Tabel 3.9 Contoh Perhitungan Bobot IDF

Perhitungan dalam tabel tersebut bertujuan untuk mengetahui apakah term yang dicari cocok dengan kata kunci yang diinginkan, term yang sering muncul akan memberikan pengaruh yang kecil dalam menentukan relevansi. Bobot IDF diperoleh dengan menggunakan rumus 2.1

(3) Tabel 3.10 Contoh Perhitungan Bobot TF-IDF

Perhitungan dalam tabel tersebut bertujuan untuk mengetahui kata yang penting atau sering muncul dalam dokumen. Adapun dari perhitungan

dalam tabel tersebut dapat disimpulkan bahwa kata “trisandia” merupakan kata dengan bobot IDF terkecil yang menandakan bahwa kalimat tersebut paling sering muncul dalam contoh ulasan Kalender Bali pada *website Google Play Store*.

3.3.5. Pembagian Data

Sebelum masuk ke proses klasifikasi, data terlebih dahulu dibagi menjadi data *training* dan data *testing*. Penelitian ini menggunakan *k-Fold Cross Validation* untuk pembagian data. Nilai k yang akan digunakan pada penelitian ini adalah 3, 5, 7, dan 9. Contoh penerapan *k-Fold Cross Validation* menggunakan $k=3$ pada ulasan aplikasi Kalender Bali yang termasuk rentang waktu data setelah covid dapat dilihat pada tabel 3.12.

Tabel 3. 12 Contoh Penerapan *K-Fold Crossvalidation*

K = 3						
FOLD 1	D1	D2	D3	D4	D5	D6
FOLD 2	D1	D2	D3	D4	D5	D6
FOLD 3	D1	D2	D3	D4	D5	D6


Keterangan :

	: Data <i>Testing</i>
	: Data <i>Training</i>
D	: Dokumen

Dalam tabel 3.12 tersebut, *k-Fold Cross Validation* menggunakan $k=3$. Dokumen kemudian dibagi menjadi 3 bagian yang sama. Proses pelatihan dan evaluasi akan dilakukan sebanyak 3 kali, di mana setiap kali salah satu dokumen digunakan sebagai data uji (*testing*) maka dokumen yang lainnya digunakan sebagai data latih (*training*).

3.3.6. Klasifikasi

Setelah melalui semua proses diatas maka selanjutnya adalah tahap klasifikasi yang dilakukan dengan menggunakan metode KNN. KNN merupakan metode klasifikasi yang mengelompokkan data baru berdasarkan jarak data baru ke beberapa data atau tetangga terdekat. Berikut merupakan alur dari proses klasifikasi :



Gambar 3. 13 Diagram Alir *K-Nearest Neighbor*

Berdasarkan gambar 3.13, proses klasifikasi dengan KNN dimulai dengan menginisialisasi data latih (*training*) dan data uji (*testing*) yang dihasilkan dari proses pembagian data. Langkah selanjutnya adalah input nilai *k* atau *neighbor* 3, 5, 7, dan 9. Lakukan penghitungan jarak *Euclidean* antara data *training* dan data *testing*. Setelah jarak didapatkan maka lakukan pengurutan data *training* berdasarkan jarak yang terkecil ke jarak terbesar (tertinggi). Lalu *k* data *training* yang memiliki jarak paling dekat dengan data *testing* dipilih sebagai tetangga (*neighbor*) terdekat. Label mayoritas dari tetangga terdekat tersebut akan dijadikan

label prediksi untuk data *testing*. Setelah semua Langkah dilakukan dengan benar, maka didapatkan label untuk kelas prediksi. Contoh penerapan KNN pada ulasan aplikasi Kalender Bali yang termasuk rentang waktu data setelah covid dapat dilihat pada tabel 3.13 hingga tabel 3.15.

Tabel 3. 13 *Euclidean Distance* untuk *Fold* 1 Data Tidak Seimbang

Data Training					Data Testing	Euclidean Distance	
D2	D3	D4	D5	D6	D1		
0	0	0	0	0	0.778	D1, D2	1.984071
0	0	0	0	0	0.778	D1, D3	1.506954
0	0	0	0	0.477	0.477	D1, D4	2.475913
0	0	0	0	0.477	0.477	D1, D5	1.695935
0.778	0	0	0	0	0	D1, D6	1.627472
0.778	0	0	0	0	0		
0.778	0	0	0	0	0		
0.477	0	0	0	0.477	0		
0.477	0	0.477	0	0	0		
0	0.778	0	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0	0.778	0		
0	0	0	0	0.778	0		
0	0	0	0	0	0.778		
0	0	0	0	0	0.778		

Tabel 3.13 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *fold* 1 dengan dokumen 1 (D1) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Adapun nilai TF-IDF yang digunakan pada perhitungan jarak *euclidean* ini adalah nilai pembulatan. Jarak *Euclidean* terkecil berada pada dokumen 3 sehingga dokumen 3 diprediksi memiliki label yang sama dengan dokumen 1 yakni negatif. Namun, prediksi ini salah karena label yang

sebenarnya dari dokumen 3 adalah positif. Oleh karena itu, pada *fold* 1 dokumen 1 dianggap *false negative*.

Tabel 3. 14 *Euclidean Distance* untuk *Fold* 2 Data Tidak Seimbang

Data Training					Data Testing	Euclidean Distance	
D1	D3	D4	D5	D6	D2		
0.778	0	0	0	0	0	D2, D1	1.984071
0.778	0	0	0	0	0	D2, D3	1.695935
0.477	0	0	0	0.477	0	D2, D4	2.506066
0.477	0	0	0	0.477	0	D2, D5	1.865872
0	0	0	0	0	0.778	D2, D6	1.925878
0	0	0	0	0	0.778		
0	0	0	0	0	0.778		
0	0	0	0	0.477	0.477		
0	0	0.477	0	0	0.477		
0	0.778	0	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0.778	0	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0	0.778	0		
0	0	0	0	0.778	0		
0	0	0	0	0	0.778		
0	0	0	0	0.778	0		

Tabel 3.14 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *Fold* 2 dengan dokumen 2 (D2) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Jarak *Euclidean* terkecil berada pada dokumen 3 sehingga dokumen 3 diprediksi memiliki label yang sama dengan dokumen 2 yakni positif. Prediksi ini benar sehingga pada *fold* 2 dokumen 2 dianggap *true positive*.

Tabel 3. 15 *Euclidean Distance* untuk *Fold 3* Data Tidak Seimbang


Data Training					Data Testing	Euclidean Distance	
D1	D2	D3	D4	D6	D5		
0.778	0	0	0	0	0	D5, D1	1.695935
0.778	0	0	0	0	0	D5, D2	1.865872
0.477	0	0	0	0.477	0	D5, D3	2.382244
0.477	0	0	0	0.477	0	D5, D4	2.382244
0	0.778	0	0	0	0	D5, D6	1.761739
0	0.778	0	0	0	0		
0	0.778	0	0	0	0		
0	0.477	0	0	0.477	0		
0	0.477	0	0.477	0	0		
0	0	0.778	0	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0.778	0	0		
0	0	0	0	0	0.778		
0	0	0	0	0	0.778		
0	0	0	0	0.778	0		
0	0	0	0	0.778	0		

Tabel 3.15 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *fold 3* dengan dokumen 5 (D5) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Jarak *Euclidean* terkecil berada pada dokumen 1 sehingga dokumen 1 diprediksi memiliki label yang sama dengan dokumen 5 yakni positif. Namun, prediksi ini salah karena label yang sebenarnya dari dokumen 1 adalah negatif. Oleh karena itu, pada *fold 3* dokumen 5 dianggap *false positive*.

3.3.7. *Balancing Data*

Pada tahap ini *balancing* data dilakukan dengan *Tomek Links undersampling* yang melakukan penyeimbangan data dengan mengurangi jumlah sampel mayoritas yang posisinya berdekatan dengan sampel minoritas yang berada di sekitarnya.

Gambar 3. 14 Ilustrasi distribusi data sebelum dan setelah *Tomek Link*



Dari gambar 3.14 terlihat pengurangan jumlah data pada sampel mayoritas sebanyak 2 data. Berikut merupakan tabel data sebelum dan setelah *balancing* data untuk melihat data mana saja yang terhapus.

Tabel 3. 16 Data sebelum dan setelah *balancing* data

Sebelum <i>Balancing</i> Data		Setelah <i>Balancing</i> Data menggunakan <i>Tomek Links</i>	
Data	Label Sentimen	Data	Label Sentimen
[non, muslim, kalender, kuhapus]	Negatif	[non, muslim, kalender, kuhapus]	Negatif
[bagus, tanggal, merah, alarm, trisandia]	Positif	[bagus, tanggal, merah, alarm, trisandia]	Positif

Sebelum <i>Balancing</i> Data		Setelah <i>Balancing</i> Data menggunakan <i>Tomek Links</i>	
Data	Label Sentimen	Data	Label Sentimen
[bermanfaat]	Positif	[membantu, weton]	Positif
[terima, kasih, kewajiban, trisandia, aplikasinya, orang, hindu, tulen]	Positif	[alarm, kalender, fungsi, baik, hapus]	Negatif
[membantu, weton]	Positif		
[alarm, kalender, fungsi, baik, hapus]	Negatif		

Dari tabel 3.16 dapat dilihat bahwa terjadi penurunan jumlah data berlabel mayoritas yaitu data positif mengalami penurunan jumlah dari 4 dokumen menjadi 2 dokumen. Adapun dokumen yang dihapus pada tabel tersebut merupakan dokumen positif yang posisinya berdekatan dengan dokumen negatif yang berada di sekitarnya. Dalam hal ini, dokumen 3 dan dokumen 4 memiliki posisi terdekat ke dokumen negatif 1 maupun 6 sehingga dokumen 3 dan 4 dihapuskan saat melakukan proses *balancing* dataset.

3.3.8. Klasifikasi Menggunakan *Balanced* Dataset

Setelah melalui *balancing* data dan diperoleh balanced dataset, maka selanjutnya adalah melakukan klasifikasi dengan menggunakan metode KNN. Contoh penerapan KNN pada *balanced dataset* ulasan aplikasi Kalender Bali yang termasuk rentang waktu data setelah covid dapat dilihat pada tabel 3.17 hingga tabel 3.19.

Tabel 3. 17 *Euclidean Distance* untuk *Fold 1* Data Seimbang

Data Training			Data Testing	Euclidean Distance	
D2	D5	D6	D1		
0	0	0	0.778	D1, D2	1.984071
0	0	0	0.778	D1, D5	1.695935
0	0	0.477	0.477	D1, D6	1.429469
0	0	0.477	0.477		
0.778	0	0	0		
0.778	0	0	0		
0.778	0	0	0		
0.477	0	0.477	0		
0.477	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0.778	0	0		
0	0.778	0	0		
0	0	0.778	0		
0	0	0.778	0		

Tabel 3.17 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *fold 1* dengan dokumen 1 (D1) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Jarak *Euclidean* terkecil berada pada dokumen 6 sehingga dokumen 6 diprediksi memiliki label yang sama dengan dokumen 1 yakni negatif. Prediksi ini benar sehingga pada *fold 1* dokumen 1 dianggap *true negative*..

Tabel 3. 18 *Euclidean Distance* untuk *Fold 2* Data Seimbang

Data Training			Data Testing	Euclidean Distance	
D1	D5	D6	D2	D2, D1	
0.778	0	0	0	1.984071	
0.778	0	0	0	1.865872	
0.477	0	0.477	0	1.925878	
0.477	0	0.477	0		
0	0	0	0.778		
0	0	0	0.778		
0	0	0	0.778		
0	0	0.477	0.477		
0	0	0	0.477		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0	0	0		
0	0.778	0	0		
0	0.778	0	0		
0	0	0.778	0		
0	0	0.778	0		

Tabel 3.18 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *fold 2* dengan dokumen 2 (D2) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Jarak *Euclidean* terkecil berada pada dokumen 5 sehingga dokumen 5 diprediksi memiliki label yang sama dengan dokumen 2 yakni positif. Prediksi ini benar sehingga pada *fold 2* dokumen 2 dianggap *true positive*.

Tabel 3. 19 *Euclidean Distance* untuk *Fold 3* Data Seimbang

Data Training			Data Testing		Euclidean Distance	
D1	D2	D6	D5			
0.778	0	0	0		D5, D1	1.695935
0.778	0	0	0		D5, D2	1.865872
0.477	0	0.477	0		D5, D6	1.761739
0.477	0	0.477	0			
0	0.778	0	0			
0	0.778	0	0			
0	0.778	0	0			
0	0.477	0.477	0			
0	0.477	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0			
0	0	0	0.778			
0	0	0	0.778			
0	0	0.778	0			
0	0	0.778	0			

Tabel 3.19 merupakan perhitungan jarak *Euclidean* yang menggunakan persamaan 2.1, untuk *fold 3* dengan dokumen 5 (D5) sebagai data *testing* dan dokumen lainnya sebagai data *training*. Jarak *Euclidean* terkecil berada pada dokumen 1 sehingga dokumen 1 diprediksi memiliki label yang sama dengan dokumen 5 yakni positif. Namun, prediksi ini salah karena label yang sebenarnya dari dokumen 1 adalah negatif. Oleh karena itu, pada *fold 3* dokumen 5 dianggap *false positive*.

3.3.9. Evaluasi

Untuk tahap evaluasi, penelitian ini akan menggunakan tabel *confusion matrix*. Adapun *confusion matrix* untuk ketiga fold pada klasifikasi KNN tanpa *balancing* data menggunakan *Tomek Links* dapat dilihat pada tabel 3.20 hingga tabel 3.22, kemudian untuk *confusion matrix* total dapat dilihat pada tabel 3.23.

Tabel 3. 20 *Confusion Matrix* untuk *Fold 1* Data Tidak Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	0	0
	<i>Negative</i>	1	0

Tabel 3. 21 *Confusion Matrix* untuk *Fold 2* Data Tidak Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	1	0
	<i>Negative</i>	0	0

Tabel 3. 22 *Confusion Matrix* untuk *Fold 3* Data Tidak Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	0	1
	<i>Negative</i>	0	0

Tabel 3. 23 *Confusion Matrix* Total Data Tidak Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	1	1
	<i>Negative</i>	1	0

Dari *confusion matrix* diatas, selanjutnya dapat dicari nilai akurasi, presisi dan juga *recall*. Akurasi merepresentasikan seberapa baik model klasifikasi berhasil mengklasifikasikan data dengan benar. Nilai akurasi didapat menggunakan persamaan 2.3, sehingga nilai akurasi klasifikasi diatas adalah :

$$Akurasi = \frac{TP+TN}{TP+FP+TN+FN} = \frac{1+0}{1+1+0+1} = \frac{1}{3} = 0.33 = 33\%$$

Kemudian presisi akan merepresentasikan tingkat ketepatan antara informasi yang diminta oleh pengguna dengan jawaban yang diberikan oleh sistem. Nilai presisi didapat menggunakan persamaan 2.4, sehingga nilai presisi klasifikasi diatas adalah :

$$Presisi = \frac{TP}{TP+FP} = \frac{1}{1+1} = \frac{1}{2} = 0,5 = 50\%$$

Yang terakhir evaluasi menggunakan *recall*, dimana *recall* akan merepresentasikan tingkat keberhasilan sistem dalam menemukan kembali sebuah informasi. Nilai *recall* didapat menggunakan persamaan 2.5, sehingga nilai *recall* klasifikasi diatas adalah :

$$Recall = \frac{TP}{TP+FN} = \frac{1}{1+1} = \frac{1}{2} = 0.5 = 50\%$$

Yang terakhir evaluasi menggunakan *f1 score*, dimana *f1 score* akan merepresentasikan mengenai seberapa baik model dalam mengklasifikasikan semua sentimen ulasan baik itu ulasan positif maupun ulasan negatif secara akurat. Nilai *f1 score* didapat menggunakan persamaan 2.6, sehingga nilai *f1 score* klasifikasi diatas adalah :

$$F1\ score = 2 \times \frac{recall \times presisi}{recall + presisi} = 2 \times \frac{0.5 \times 0.5}{0.5 + 0.5} = 2 \times \frac{1}{4} = \frac{1}{2} = 0.5 = 50\%$$

Untuk tahap evaluasi yang kedua, penelitian masih akan menggunakan tabel *confusion matrix*. Adapun *confusion matrix* untuk ketiga fold pada klasifikasi KNN dengan *balancing* data menggunakan *Tomek Links* dapat dilihat pada tabel 3.24 hingga tabel 3.26, kemudian untuk *confusion matrix* total dapat dilihat pada tabel 3.27.

Tabel 3. 24 *Confusion Matrix* untuk *Fold 1* Data Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	0	0
	<i>Negative</i>	0	1

Tabel 3. 25 *Confusion Matrix* untuk *Fold 2* Data Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	1	0
	<i>Negative</i>	0	0

Tabel 3. 26 *Confusion Matrix* untuk *Fold 3* Data Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	0	1
	<i>Negative</i>	0	0

Tabel 3. 27 *Confusion Matrix* Total Data Seimbang

		<i>Actual</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Predicted</i>	<i>Positive</i>	1	1
	<i>Negative</i>	0	1

Dari *confusion matrix* diatas, selanjutnya dapat dicari nilai akurasi, presisi dan juga *recall*. Akurasi merepresentasikan seberapa baik model klasifikasi berhasil mengklasifikasikan data dengan benar. Nilai akurasi didapat menggunakan persamaan 2.3, sehingga nilai akurasi klasifikasi diatas adalah :

$$Akurasi = \frac{TP+TN}{TP+FP+TN+FN} = \frac{1+1}{1+1+0+1} = \frac{2}{3} = 0.67 = 67\%$$

Kemudian presisi akan merepresentasikan tingkat ketepatan antara informasi yang diminta oleh pengguna dengan jawaban yang diberikan oleh sistem. Nilai presisi didapat menggunakan persamaan 2.4, sehingga nilai presisi klasifikasi diatas adalah :

$$Presisi = \frac{TP}{TP+FP} = \frac{1}{1+1} = \frac{1}{2} = 0.5 = 50\%$$


Yang terakhir evaluasi menggunakan *recall*, dimana *recall* akan merepresentasikan tingkat keberhasilan sistem dalam menemukan kembali sebuah informasi. Nilai *recall* didapat menggunakan persamaan 2.5, sehingga nilai *recall* klasifikasi diatas adalah :

$$Recall = \frac{TP}{TP+FN} = \frac{1}{1+0} = \frac{1}{1} = 1 = 100\%$$

Yang terakhir evaluasi menggunakan *f1 score*, dimana *f1 score* akan merepresentasikan mengenai seberapa baik model dalam mengklasifikasikan semua sentimen ulasan baik itu ulasan positif maupun ulasan negatif secara akurat. Nilai *f1 score* didapat menggunakan persamaan 2.6, sehingga nilai *f1 score* klasifikasi diatas adalah :

$$F1\ score = 2 \times \frac{recall \times presisi}{recall + presisi} = 2 \times \frac{1 \times 0.5}{1 + 0.5} = 2 \times \frac{1}{3} = \frac{2}{3} = 0.67 = 67\%$$

Perbandingan hasil evaluasi klasifikasi tanpa *balancing* maupun klasifikasi dengan *balancing* dapat dilihat pada gambar 3.15.



Gambar 3. 15 Perbandingan Hasil Evaluasi

Pada gambar 3.15 dapat dilihat perbandingan antara hasil evaluasi klasifikasi KNN serta hasil evaluasi klasifikasi KNN menggunakan *balancing* data *Tomek Links*. Untuk klasifikasi KNN tanpa *balancing* data didapatkan akurasi sebesar 33%, presisi sebesar 50%, *recall* sebesar 50% serta nilai *f1 score* sebesar 50%. Untuk klasifikasi dengan *balancing* data menggunakan *Tomek Links* didapatkan akurasi sebesar 67%, presisi sebesar 50%, *recall* sebesar 100% serta nilai *f1 score* sebesar 67%. Dari hasil tersebut, klasifikasi menggunakan *balancing* mendapatkan akurasi dan *recall* yang lebih tinggi dibandingkan klasifikasi tanpa *balancing*. Dapat disimpulkan bahwa hasil

3.3.10. Skenario Pengujian

Penelitian ini menggunakan metode KNN untuk klasifikasi serta *balancing* data menggunakan *Tomek Links*. Pada tahap awal dilakukan proses *pre-processing* agar didapatkan data ulasan yang bersih dan siap digunakan untuk proses selanjutnya. Tahap *pre-processing*, meliputi *labeling*, *case folding* dan *cleaning*, *tokenizing*, *normalization*, *stemming*, serta *stopword removal*. Untuk tahap *labeling*, data akan diberi label sentimen positif dan sentimen negatif. Selanjutnya dilakukan pembagian rentang waktu data untuk sebelum dan setelah covid. Untuk langkah selanjutnya dapat dilihat pada tabel 3.18.

Tabel 3. 28 Skenario Pengujian

Data	Nilai k (neighbor)	Random state	Nilai k untuk k-fold	Pengujian
Data sebelum covid	3, 5, 7, dan 9	42	3, 5, 7, dan 9	PA1-PA4
Data setelah covid	3, 5, 7, dan 9	42	3, 5, 7, dan 9	PB1-PB4
Data sebelum covid menggunakan <i>Tomek Links</i>	3, 5, 7, dan 9	42	3, 5, 7, dan 9	PA5-PA8
Data setelah covid menggunakan <i>Tomek Links</i>	3, 5, 7, dan 9	42	3, 5, 7, dan 9	PB5-PB8

Pada tabel 3.28, masing-masing rentang waktu data, sebelum maupun setelah covid pada pengujian PA1-PA4 serta PB1-PB4, akan dilakukan pembobotan kata, pembagian data, klasifikasi, dan terakhir evaluasi. Pembobotan kata dilakukan dengan menggunakan teknik TF-IDF untuk membentuk vektor antara dokumen dan kata. Setelah itu data akan dibagi menggunakan *k-Fold Cross Validation* menggunakan nilai k yaitu 3, 5, 7 dan 9 serta *random state* sebesar 42 untuk

mendapatkan data *training* dan data *testing* yang akan digunakan dalam proses klasifikasi menggunakan metode KNN. Nilai k yang digunakan untuk proses klasifikasi KNN adalah 3, 5, 7, dan 9. Proses evaluasi kemudian dilakukan dengan *confusion matrix* untuk mendapatkan akurasi, presisi dan *recall*, dan *f1 score* dari masing-masing pengujian.

Untuk pengujian PA5-PA8 serta PB5-PB8, dilakukan pembobotan kata, pembagian data, *balancing* data, klasifikasi, dan terakhir evaluasi untuk masing-masing pengujian. Pembobotan kata masih dilakukan dengan teknik yang sama yaitu TF-IDF untuk membentuk vektor antara dokumen dan kata. Setelah itu data akan dibagi menggunakan *k-Fold Cross Validation* menggunakan nilai yaitu 3, 5, 7 dan 9 serta *random state* sebesar 42 untuk mendapatkan data *training* dan data *testing*. Data *training* kemudian diseimbangkan (*balancing*) menggunakan *Tomek Links*. Pada tahap *balancing*, data *training* dengan label mayoritas akan dilakukan penurunan jumlah data. Setelah mendapat data seimbang (*balanced dataset*), maka selanjutnya adalah melakukan klasifikasi dengan KNN. Nilai k yang digunakan pada proses klasifikasi KNN masih sama dengan nilai k pada pengujian sebelumnya yaitu 3, 5, 7, dan 9. Proses akhir dari penelitian ini adalah melakukan evaluasi dengan *confusion matrix* yang terdiri dari akurasi, presisi dan *recall*, dan *f1 score*.

3.4 Kebutuhan Hardware dan Software

3.4.1. Spesifikasi *Hardware*

1. *Processor Intel(R) Core(TM) i5-8265U CPU @ 1.60GHz 1.80 GHz*
2. RAM : 4 GB

3.4.2. Spesifikasi *Software*

1. Sistem Operasi Windows 11
2. *Google Colaboratory*

BAB IV

IMPLEMENTASI HASIL DAN ANALISIS HASIL

Bab ini membahas mengenai implementasi dan analisis hasil dari proses pengolahan data, yang meliputi tahapan-tahapan seperti pengambilan data, *pre-processing*, pembagian rentang waktu data, pembobotan kata, pembagian data, klasifikasi dataset dengan KNN serta klasifikasi KNN menggunakan data yang telah diseimbangkan dengan *Tomek Links*.

4.1 Implementasi Pengumpulan Data

Pengumpulan data dilakukan dengan menggunakan teknik *webscrapping* dengan *package google-play-scraper* dari Bahasa pemrograman *python*. Data yang diambil merupakan data ulasan terhadap aplikasi *Google Play Store* yaitu Kalender Bali. Data yang telah diambil kemudian disimpan ke dalam bentuk *csv*. Tujuan pengambilan data tersebut adalah untuk memperoleh dataset yang akan digunakan untuk proses analisis sentimen. Implementasi *source code* untuk proses pengumpulan data dapat dilihat pada gambar 4.1.

```
# Install library untuk mengekstrak data dari Google Play Store
!pip install google-play-scraper
from google_play_scraper import Sort, reviews_all
import pandas as pd
import numpy as np

# Scrapping data ulasan aplikasi 'Kalender Bali' dari Google Play
result = reviews_all( # memanggil fungsi reviews_all untuk mengambil ulasan
    'com.alitmd.kalenderbali', # ID paket aplikasi Kalender Bali di Google Play Store
    sleep_milliseconds=0, # menghilangkan penundaan atau jeda dalam program saat eksekusi kode
    lang='id', # bahasa ulasan yang diambil menggunakan bahasa indonesia
    country='id', # mengatur Indonesia sebagai negara untuk sumber ulasan yang diambil
    sort=Sort.NEWEST, # mengatur pengurutan ulasan dari yang terbaru
)

# Inisialisasi hasil scrapping data ke dalam data frame
df_scrap = pd.DataFrame(np.array(result), columns=['review'])
df_scrap = df_scrap.join(pd.DataFrame(df_scrap.pop('review').tolist()))
# Menyimpan hasil scrapping data ke dalam file csv
df_scrap.to_csv("/content/drive/MyDrive/SKRIPSI♥/proses 1_scraping data/scrappFullKalenderBali.csv")
```

Gambar 4. 1 *Source Code* Pengumpulan Data

Terlihat dari gambar 4.1, proses pengumpulan data dimulai dengan meng-*install* dan meng-*import package google-play-scraper* untuk dapat melakukan *webscrapping* serta meng-*import library* *pandas* dan *numpy* untuk membantu proses pengolahan data. Langkah selanjutnya adalah melakukan *scrapping* data dengan memanggil fungsi *reviews_all* kemudian mengisi parameter ID paket dengan ID paket dari aplikasi Kalender Bali, mengisi parameter *lang* atau bahasa dengan id untuk Bahasa Indonesia, mengisi parameter *country* atau negara dengan id untuk Indonesia sebagai negara untuk sumber ulasan diambil, serta mengisi parameter *sort* dengan *sort.NEWEST* agar ulasan terurut dari yang terbaru. Setelah proses *scrapping* berhasil, selanjutnya data tersebut di-inisialisasi ke dalam data frame untuk kemudian disimpan ke dalam file berbentuk csv. Contoh data ulasan aplikasi Kalender Bali dapat dilihat pada gambar 4.2.

	reviewId	userName	userImage	content	score	thumbsUp	reviewCreatedAt	replyContent	repliedAt	appVersion
0	f6e6dcce-1	sutiawan a	https://play	SUKSEMA	5	0	6/28/2023 6:03			
1	63c37eb3-	Ketut Madr	https://play	Bagus sangat berma	5	0	3.4.9 6/27/2023 5:14			3.4.9
2	568d9e7c-	Komang Ar	https://play	Aplikasi yang bagus	5	0	6/21/2023 3:50			
3	c37e79db-	Komang Pe	https://play	Sangat bagus memu	5	0	3.5.2 6/19/2023 6:02			3.5.2
4	ff771add-	Adiatana	https://play	Sangat membantu	5	0	3.5.2 6/17/2023 4:18			3.5.2
5	7c7a7666-	Komang Su	https://play	Sangat membantu d	5	0	6/17/2023 3:57			
6	ff034be6-	KurangNan	https://play	Saat lupa hari purna	5	0	3.5.2 6/16/2023 12:11			3.5.2
7	f3f0469f-c	Mama Billy	https://play	Pokoknya ini aplikasi	5	0	3.5.2 6/13/2023 23:16			3.5.2
8	dc5b447a-	Andi Perma	https://play	Sangat bagus sekali	5	0	3.5.2 6/13/2023 15:45			3.5.2
9	1c2575fe-	Ieva dian le	https://play	Kenapa ya kalau gak	2	0	3.5.2 6/13/2023 4:03			3.5.2
10	9af83b99-	Ni luh Padn	https://play	Suksma	5	0	3.5.2 6/9/2023 20:51			3.5.2
11	546cc5cf-	Raja Rimba	https://play	Non muslim kalende	1	0	6/6/2023 11:04			
12	b2fc735c-	I Dewa Ket	https://play	Bagus dan tahu kapa	5	0	3.5.2 6/4/2023 13:13			3.5.2
13	a1c02726-	I Wayan Gu	https://play	Sangat bermanfaat	5	0	3.4.9 6/1/2023 13:14			3.4.9
14	3584a871-	Ajik Mika	https://play	Trimakasih. Slu diing	5	0	3.5.2 6/1/2023 10:04			3.5.2
15	c2c0b4a9-	Kristin Nurl	https://play	Sangat membantu se	5	0	3.5.2 5/31/2023 10:53			3.5.2

Gambar 4. 2 Hasil Pengumpulan Data

Dari proses pengumpulan data pada gambar 4.2, didapatkan sejumlah 5617 ulasan mengenai aplikasi Kalender Bali untuk periode 4 Agustus 2013 hingga 28 Juni 2023. Dataset terdiri dari 11 kolom yaitu *reviewId*, *username*, *userImage*, *content*, *score*, *thumbsUp*, *reviewCreate*, *at*, *replyContent*, *repliedAt*, serta

appversion. Dari 11 kolom hanya 4 kolom yang digunakan dalam proses selanjutnya yaitu *username*, *content*, *score* dan *at*. Pemilihan kolom dilakukan dengan *source code* pada gambar 4.3.

```
# Mengambil kolom data yang diperlukan
new_df = df_scrap[['userName', 'at', 'content', 'score']]
```

Gambar 4.3 *Source Code* Pemilihan Kolom

Berikut merupakan contoh dataset setelah menerapkan *source code* pada gambar 4.3.

	userName	at	content	score
0	sutiawan agus	2023-06-28 06:03:46	SUKSEMA	5
1	Ketut Madri	2023-06-27 05:14:14	Bagus sangat bermanfaat	5
2	Komang Ariadi	2023-06-21 03:50:16	Aplikasi yang bagus	5
3	Komang Pebiyanti	2023-06-19 06:02:07	Sangat bagus memudahkan saya untuk mengingat h...	5
4	Adiatana	2023-06-17 04:18:30	Sangat membantu	5

Gambar 4.4 Contoh Dataset Setelah Menggunakan Kolom Terpilih

Pada gambar 4.4, telah terlihat dataset dengan 4 kolom terpilih. Adapun alasan mempertahankan kolom tersebut adalah :

1. Kolom *username* digunakan untuk mengetahui nama pengguna yang memberikan ulasan
2. Kolom *at* atau waktu pengunggahan ulasan digunakan untuk melakukan pembagian rentang waktu data
3. Kolom *content* atau ulasan digunakan untuk melakukan analisis sentimen
4. Kolom *score* atau nilai digunakan untuk proses *labeling* saat *pre-processing data*.

4.2 Implementasi *Pre-processing*

Setelah memperoleh dataset dari hasil scrapping, selanjutnya masuk ke tahap *pre-processing*. Tahapan *pre-processing* dilakukan untuk memperoleh data yang siap digunakan untuk tahapan berikutnya. *Pre-processing* terdiri dari *labeling*, *case folding* dan *cleaning*, *tokenizing*, *normalization*, *stemming*, serta *stopword removal*.

4.2.1 *Labeling*

Pelabelan data atau *labeling* dilakukan untuk mendapatkan label positif dan label negatif dari dataset. Implementasi *source code* untuk proses *labeling* dapat dilihat pada gambar 4.5.

```
sentimen = []
for index, row in new_df.iterrows():
    if row['score'] > 3 :
        sentimen.append('1') # Score 4,5 (positif)
    else :
        sentimen.append('0') # Score 1,2,3 (negatif)
new_df['sentiment'] = sentimen
```

Gambar 4. 5 *Source Code Labeling*

Tahap *labeling* pada gambar 4.5 dilakukan berdasarkan nilai *score* ulasan aplikasi Kalender Bali. Ulasan dengan *score* lebih dari 3 yaitu *score* 4 dan 5 akan diberi label sentimen positif sedangkan ulasan dengan *score* kurang dari sama dengan 3 yaitu *score* 1, 2, dan 3 akan diberi label sentimen negatif. Untuk mempermudah proses selanjutnya, sentimen positif diwakili oleh angka 1 dan sentimen negatif diwakili oleh angka 0. Dari 5617 data, diperoleh data dengan label positif sejumlah 5123 data dan data dengan label negatif sejumlah 494 data. Contoh hasil *labeling* dapat dilihat pada tabel 4.1.

Tabel 4. 1 Contoh Hasil *Labeling*

Data Ulasan Mentah	Score	Sentimen
Pokoknya ini aplikasi sngat membantu 🥰🙏🙏	5	1
Sangat bagus sekali	5	1
Kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau.. Padahal dulu baik" Aja udh ngikutin cara setting yg di saranin juga tetep gak mau..	2	0
Suksma	5	1
Non muslim kalender...sdh kuhapus..	1	0
👍👍👍	5	1

4.2.2 Case folding dan Cleaning

Tahap selanjutnya adalah *case folding* dan *cleaning*. Setiap huruf dalam data akan diubah menjadi huruf kecil kemudian karakter selain huruf yang tidak diperlukan seperti tanda baca, angka serta simbol yang tidak memiliki relevansi dengan dokumen akan dihilangkan. Implementasi *source code* untuk proses *case folding* dan *cleaning* dapat dilihat pada gambar 4.6.

```
new_df['content'] = new_df['content'].str.lower()
import re
def clean_content(input_content):
    # Cek apakah input sebuah string
    if isinstance(input_content, str):
        # Hapus karakter selain huruf dan spasi
        cleaned_content = re.sub(r'^a-zA-Z\s', ' ', input_content)
        # Hapus spasi berlebih
        cleaned_content = ' '.join(cleaned_content.split())
        return cleaned_content
    else:
        return input_content
# Membersihkan dan memperbarui kolom 'content'
new_df['content'] = new_df['content'].apply(clean_content)
```

Gambar 4. 6 Source Code Case Folding dan Cleaning

Tahapan *case folding* dilakukan dengan memanggil metode `‘.str.lower()’` dari *library pandas* untuk mengubah semua karakter dalam teks menjadi huruf kecil

(*lowercase*). Kemudian meng-*import library re (regular expression)* untuk membantu proses *cleaning* data. *Cleaning* dilakukan dengan fungsi `clean_content` yang memuat fungsi '*isinstance*' untuk melakukan pengecekan tipe data terlebih dahulu. Untuk data yang menggunakan tipe string akan dilakukan penghapusan karakter selain huruf dan spasi menggunakan modul *re (regular expression)*. Setelah karakter selain huruf dihapus maka karakter tersebut akan digantikan oleh sebuah spasi. Pada tahapan ini juga dilakukan penghapusan spasi berlebih agar hasil *cleaning* yang diperoleh lebih mudah dipahami. Contoh hasil *case folding* dan *cleaning* dapat dilihat pada tabel 4.2.

Tabel 4. 2 Contoh Hasil *Case Folding* dan *Cleaning*

Data Ulasan (Mentah)	Hasil Proses <i>Case Folding</i> dan <i>Cleaning</i>
Pokoknya ini aplikasi sngat membantu 🥰🙏🙏	pokoknya ini aplikasi sngat membantu
Sangat bagus sekali	sangat bagus sekali
Kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau.. Padahal dulu baik" Aja udh ngikutin cara setting yg di saranin juga tetep gak mau..	kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau padahal dulu baik aja udh ngikutin cara setting yg di saranin juga tetep gak mau
Suksma	suksma
Non muslim kalender...sdh kuhapus..	non muslim kalender sdh kuhapus
👍👍👍	<i>null</i>

Dari tabel 4.2, terlihat bahwa terdapat kolom yang kosong (*null*) akibat ulasan hanya berisi emoji (bukan huruf) sehingga akan dilakukan penghapusan

beberapa baris data yang memuat ulasan kosong seperti data tersebut menggunakan code pada gambar 4.7.

```
# Cleaning 1 baris yg memuat content/ulasan kosong --> null
new_df = new_df.dropna()

# Menghapus 36 baris index yg ulasannya kurang relevan untuk digunakan sebagai dataset
new_df = new_df.drop([70, 305, 378, 478, 592, 629, 894, 1228, 1454, 1516,
1663, 1976, 2029, 3348, 3859, 4044, 4190, 4540, 4626, 4671,
4758, #ulasan tidak dapat dipahami
107, 3552, #hanya berisi nama daerah
100, #membahas hewan
877, 5166, #membahas game
1430, 1853, #hanya tanggal/bulan tidak ada arti
196, 856, 881, 1234, 1778, 1854, 5151, 5235 #hanya berisi userName
])
```

Gambar 4. 7 Source Code Cleaning Row

Cleaning baris (*row*) kosong dilakukan dengan menggunakan metode ‘*dropna*’ dari *library pandas*. Metode tersebut akan menghapus satu baris data yang memuat nilai kosong atau *null*. Gambar 4.5 juga memuat *code* untuk menghapus 36 baris *index* dengan ulasan tidak kosong (*non-null*) namun ulasannya kurang relevan untuk digunakan sebagai dataset. Rincian index yang dihapus dapat dilihat pada tabel 4.3.

Tabel 4. 3 Rincian *Index* Terhapus

No index	Jumlah index	Alasan penghapusan baris index	Contoh ulasan
70, 305, 378, 478, 592, 629, 894, 1228, 1454, 1516, 1663, 1976, 2029, 3348, 3859, 4044, 4190, 4540, 4626, 4671, 4758	21 index	Ulasan tidak dapat dipahami seperti tidak menggunakan Bahasa Indonesia yang baik dan benar sehingga disimpulkan ulasan tersebut tidak ada hubungannya dengan aplikasi Kalender Bali	Ulasan di index 70 : bobo ikut obo l ko kopi polo x o bu om b i r t h d a y o shook koj jeruji ko om bibij ko go poin m dj fletibon oleh w hi honey

No index	Jumlah index	Alasan penghapusan baris index	Contoh ulasan
107, 3552	2 index	Ulasan hanya berisi nama daerah yang tidak berhubungan dengan aplikasi Kalender Bali	Ulasan di index 107 : tyanyar kubu karangasem
100	1 index	Ulasan membahas mengenai hewan yang tidak berhubungan dengan aplikasi Kalender Bali	Ulasan di index 100 : bali anj
877, 5166	2 index	Ulasan membahas mengenai permainan (<i>game</i>) yang tidak berhubungan dengan aplikasi Kalender Bali	Ulasan di index 877 : sangat stia sma game ini love supercell
1430, 1853	2 index	Ulasan hanya berisi tanggal/bulan yang tidak ada arti dan tidak berhubungan dengan aplikasi Kalender Bali	Ulasan di index 1430 : januari
196, 856, 881, 1234, 1778, 1854, 5151, 5235	8 index	Ulasan hanya berisi nama pengguna <i>google play store</i> (<i>username</i>) yang tidak berhubungan dengan aplikasi Kalender Bali	Ulasan di index 196 : wyn mngku

Setelah data dilakukan proses *cleaning row* menggunakan *source code* pada gambar 4.5, diperoleh data bersih sejumlah 5462 baris data. Adapun data dari tabel 4.2 di atas berkurang sejumlah 1 baris dikarenakan memuat nilai *null* sehingga data

telah dihapuskan dari tabel. Contoh hasil dari proses *cleaning row* dapat dilihat pada tabel 4.4.

Tabel 4. 4 Contoh Hasil *Cleaning Row*

Hasil Proses Sebelumnya (<i>Case Folding dan Cleaning</i>)	Hasil Proses <i>Cleaning Row</i>
pokoknya ini aplikasi sngat membantu	pokoknya ini aplikasi sngat membantu
sangat bagus sekali	sangat bagus sekali
kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau padahal dulu baik aja udh ngikutin cara setting yg di saranin juga tetep gak mau	kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau padahal dulu baik aja udh ngikutin cara setting yg di saranin juga tetep gak mau
suksma	suksma
non muslim kalender sdh kuhapus	non muslim kalender sdh kuhapus
<i>null</i>	

Setelah dilakukan *cleaning row*, dari tabel 4.4 tersebut dapat dilihat bahwa data berkurang sejumlah 1 baris. Sebelum *cleaning row* data berjumlah 5 baris data namun setelah proses tersebut data berubah menjadi hanya 4 baris data.

4.2.3 *Tokenizing*

Pada tahap *tokenizing* ini dilakukan pemotongan kata atau memotong kata di dalam sebuah kalimat menjadi potongan-potongan berupa token. Setiap token yang dihasilkan dalam proses ini akan dipisahkan dengan sebuah koma (,) Implementasi *source code* untuk proses *tokenizing* dapat dilihat pada gambar 4.8.

```
import nltk
nltk.download('punkt')
from nltk.tokenize import word_tokenize

def tokenizing(text):
    tokens = nltk.word_tokenize(text)
    token_words = [w for w in tokens if w.isalpha()]
    return token_words

new_df['content'] = new_df['content'].apply(lambda x: tokenizing(x))
```

Gambar 4. 8 *Source Code Tokenizing*

Pada gambar 4.8, untuk melakukan *tokenizing* diperlukan library NLTK. Langkah pertama adalah mendownload model tokenisasi Punkt dari NLTK. Selanjutnya, menggunakan fungsi `word_tokenize` dari NLTK, teks dipecah menjadi kata-kata. Fungsi `tokenizing` kemudian memastikan bahwa hanya kata-kata yang mengandung huruf yang disertakan dalam hasil akhir. *Code* kemudian diterapkan pada kolom '*content*' *DataFrame* menggunakan metode *apply*, menghasilkan *DataFrame* yang berisi daftar kata-kata yang diambil dari teks aslinya. Contoh hasil dari proses *tokenizing* dapat dilihat pada tabel 4.5.

Tabel 4. 5 Contoh Hasil *Tokenizing*

Hasil Proses Sebelumnya (<i>Cleaning Row</i>)	Hasil Proses <i>Tokenizing</i> dengan Kamus
pokoknya ini aplikasi sngat membantu	[pokoknya, ini, aplikasi, sngat, membantu]
sangat bagus sekali	[sangat, bagus, sekali]
kenapa ya kalau gak buka apl kalender balinya puja trisandya nya gak mau padahal dulu baik aja udh ngikutin cara setting yg di saranin juga tetep gak mau	[kenapa, ya, kalau, gak, buka, apl, kalender, balinya, puja, trisandya, nya, gak, mau, padahal, dulu, baik, aja, udh, ngikutin, cara, setting, yg, di, saranin, juga, tetep, gak, mau]
suksma	[suksma]

Hasil Proses Sebelumnya (<i>Cleaning Row</i>)	Hasil Proses <i>Tokenizing</i> dengan Kamus
non muslim kalender sdh kuhapus	[non, muslim, kalender, sdh, kuhapus]

4.2.4 Normalization

Pada tahap *normalization* dilakukan proses mengubah kata tidak baku menjadi kata baku. Proses *normalization* teks menggunakan kamus yang dibuat secara manual. Kamus tersebut terdiri dari Bahasa Indonesia tidak baku, Bahasa Bali, serta Bahasa Inggris yang diubah menjadi Bahasa Indonesia Baku. Kamus ini dibuat dengan pedoman Kamus Besar Bahasa Indonesia (KBBI), Kamus Bahasa Bali-Bahasa Indonesia serta bantuan dari Google *Translete* untuk menerjemahkan Bahasa Inggris. Contoh isi kamus yang akan diterapkan untuk proses *normalization* dapat dilihat pada tabel 4.6.

Tabel 4. 6 Contoh Isi Kamus *Normalization*

Jenis Bahasa	Sebelum	Sesudah (Bahasa Indonesia Baku)
Bahasa Indonesia tidak baku	aapnya	aplikasinya
	terimakasi	terima kasih
	tnggl	tanggal
	yg	yang
Bahasa Bali	trisandya	trisandia
	suskma	terima kasih
	yadnya	persembahan
Bahasa Inggris	amazing	luar biasa
	simple	sederhana
	thanks	terima kasih

Dalam kamus tersebut, terdapat total 2213 kata yang akan terganti dalam proses *normalization* untuk Bahasa Indonesia tidak baku, Bahasa Bali dan Bahasa Inggris yang diganti menjadi Bahasa Indonesia baku. Langkah selanjutnya adalah mengimplementasikan kamus ke dalam *source code*. Implementasi *source code* untuk proses *normalization* dapat dilihat pada gambar 4.9.

```
def normalization(tokens, kamus):
    result = []
    idx = 0
    n = len(tokens)

    while idx < n:
        found_match = False
        # Mencoba mencocokkan bigram dari token
        for i in range(2, 0, -1):
            bigram = ' '.join(tokens[idx:idx+i])
            if bigram in kamus:
                result.extend(kamus[bigram].split())
                idx += i
                found_match = True
                break
        if not found_match:
            result.append(tokens[idx])
            idx += 1
    return result

# Melakukan normalisasi teks pada ulasan
new_df['content'] = new_df['content'].apply(normalization,
                                             kamus=kamus_df.set_index('keyword')['replacement']
                                             .to_dict())
```

Gambar 4. 9 *Source Code Normalization Menggunakan Kamus*

Pada gambar 4.9, dilakukan normalisasi teks ulasan menggunakan fungsi *normalization*. Fungsi *normalization* iteratif melalui token dalam teks, mencoba mencocokkan bigram dengan kamus penggantian kata. Jika ditemukan kecocokan, token-token tersebut digantikan sesuai dengan kamus. Hasil normalisasi disimpan dalam variabel *result*. Proses ini memungkinkan pemrosesan lebih lanjut dengan teks yang terstruktur, dengan penerapan pada *DataFrame* '*new_df*' menggunakan kamus yang telah dibuat sebelumnya dan diletakkan dalam variabel '*kamus_df*'. Tujuan utama *normalization* adalah memperoleh teks yang telah dinormalisasi

sesuai dengan kamus yang ditentukan, kemudia memfasilitasi analisis atau pemodelan data yang lebih akurat. Contoh hasil *normalization* menggunakan *source code* pada gambar 4.9 serta kamus pada tabel 4.6 dapat dilihat pada tabel 4.7 berikut.

Tabel 4. 7 Contoh Hasil *Normalization*

Hasil Proses Sebelumnya (<i>Tokenizing</i>)	Hasil Proses <i>Normalization</i> dengan Kamus
[pokoknya, ini, aplikasi, sngat, membantu]	[pokoknya, ini, aplikasi, sangat, membantu]
[sangat, bagus, sekali]	[sangat, bagus, sekali]
[kenapa, ya, kalau, gak, buka, apl, kalender, balinya, puja, trisandya, nya, gak, mau, padahal, dulu, baik, aja, udh, ngikutin, cara, setting, yg, di, saranin, juga, tetep, gak, mau]	[kenapa, ya, kalau, gak, buka, aplikasi, kalender, balinya, puja, trisandia, nya, gak, mau, padahal, dulu, baik, saja, sudah, mengikuti, cara, pengaturan, yang, di, sarankan, juga, tetep, gak, mau]
[suksma]	[terima kasih]
[non, muslim, kalender, sdh, kuhapus]	[non, muslim, kalender, sudah, kuhapus]

Hasil pada tabel 4.7 tersebut masih belum optimal. Terdapat beberapa token yang harus digabungkan menjadi satu agar memiliki arti yang tepat. *Normalization* yang selanjutnya terdiri dari menggabungkan token ber-spasi serta menggabungkan token tanpa spazi yang dapat dilihat pada gambar 4.10 dan gambar 4.11.

```

# Fungsi normalisasi untuk token yang digabungkan dengan spasi
def normalization2(words):
    word_pairs = [('terima', 'kasih'), ('hari', 'raya'), ('orang', 'tua'), ('om', 'swastiastu'),
                  ('om', 'santi', 'santi', 'santi', 'om'), ('ida', 'sang', 'hyang', 'widhi', 'wasa'),
                  ('sang', 'hyang', 'widhi', 'wasa')]

    result = []
    idx = 0

    while idx < len(words):
        found_pair = False
        for pair in word_pairs:
            if idx + len(pair) <= len(words) and all(words[idx + i] == pair[i] for i in range(len(pair))):
                result.append(' '.join(pair))
                idx += len(pair)
                found_pair = True
                break
        if not found_pair:
            result.append(words[idx])
            idx += 1
    return result

# Melakukan normalisasi teks pada ulasan
new_df['content'] = new_df['content'].apply(normalization2)

```

Gambar 4. 10 *Source Code Normalization Menggabungkan Token Berspasi*

Pada gambar 4.10, token ber-spasi digabungkan dengan menggunakan fungsi *normalization2*. Fungsi ini menggabungkan token dengan spasi berdasarkan pasangan yang telah ditentukan dalam *word_pairs*. Proses ini dilakukan iterative atau diulang untuk setiap indeks token. Jika pasangan token sesuai, token digabungkan ke dalam hasil normalisasi, namun jika tidak, token tetap ditambahkan tanpa perubahan. Normalisasi kemudian diterapkan pada kolom '*content*' dalam *DataFrame* menggunakan metode *apply*. Pendekatan ini membantu menggabungkan token spasi untuk meningkatkan konsolidasi teks.

```

# Fungsi normalisasi untuk token yang digabungkan tanpa spasi
def normalization3(words):
    result = []
    i = 0
    while i < len(words):
        if words[i] == 'tri' and i + 1 < len(words) and words[i + 1] == 'sandia':
            result.append('trisandia')
            i += 2 # Langsung loncati 'tri' dan 'sandia' yang sudah digabungkan
        elif words[i] == 'adi' and i + 1 < len(words) and words[i + 1] == 'luhung':
            result.append('adiluhung')
            i += 2 # Langsung loncati 'adi' dan 'luhung' yang sudah digabungkan
        else:
            result.append(words[i])
            i += 1
    return result

# Melakukan normalisasi teks pada ulasan
new_df['content'] = new_df['content'].apply(normalization3)

```

Gambar 4. 11 *Source Code Normalization Menggabungkan Token Tanpa Spasi*

Pada gambar 4.11, token tanpa spasi digabungkan dengan menggunakan fungsi *normalization3*. Dalam fungsi tersebut mula-mula dilakukan pengecekan index satu-persatu kemudian jika token tri dan sandia atau adi dan luhung ditemukan maka penggabungan token tanpa spasi akan diberikan, namun jika token yang dicari tidak ditemukan maka kata yang ada pada index saat ini akan dikembalikan lagi. Normalisasi kemudian diterapkan pada kolom '*content*' dalam *DataFrame* menggunakan metode *apply*.

4.2.5 *Stemming*

Tahap *stemming* melakukan penghapusan awalan dan akhiran dari kata-kata sehingga hanya tersisa kata dasar yang relevan. Dengan melakukan *stemming*, kata-kata yang memiliki akar yang sama akan dianggap sebagai bentuk yang sama, sehingga dapat membantu dalam pengelompokan teks. Implementasi *source code* untuk proses *stemming* dapat dilihat pada gambar 4.12.

```

!pip install Sastrawi
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

factory = StemmerFactory()
stemmer = factory.create_stemmer()

# Untuk mempertahankan kata 'bali' pada saat stemming
def custom_stem(word):
    # Jika kata adalah 'bal' setelah stemming, pertahankan 'bali'
    if stemmer.stem(word) == 'bal':
        return 'bali'
    else:
        # Jika bukan 'bal', gunakan proses stemming biasa
        return stemmer.stem(word)

def stem_list(row):
    text = row['content']
    stem = [custom_stem(word) for word in text]
    return stem

# Melakukan stemming teks pada ulasan
new_df['content'] = new_df.apply(stem_list, axis=1)

```

Gambar 4. 12 *Source Code Stemming*

Pada gambar 4.12, untuk melakukan proses *stemming* atau pembentukan kata dasar pada teks, dilakukan menggunakan pustaka Sastrawi. Langkah awalnya adalah menginstal pustaka tersebut dengan menggunakan perintah ‘*!pip install Sastrawi*’. Selanjutnya, kita membuat objek *stemmer* menggunakan *StemmerFactory* dari Sastrawi. Dalam proses ini, terdapat satu kata yang dipertahankan yaitu kata 'bali' selama proses *stemming*. Oleh karena itu, untuk mendefinisikan fungsi khusus *custom_stem* untuk mempertahankan kata 'bali' selama *stemming*. Fungsi *stem_list* kemudian diterapkan pada setiap baris dalam kolom 'content' dari *DataFrame*. Fungsi ini menghasilkan daftar kata-kata setelah proses stemming, dengan memanggil fungsi *custom_stem* untuk setiap kata dalam teks. Pendekatan ini membantu menghasilkan kata-kata dasar dari setiap kata dalam teks ulasan. Contoh hasil *stemming* menggunakan *source code* pada gambar 4.12 dapat di lihat pada tabel 4.8 di bawah ini.

Tabel 4. 8 Contoh Hasil *Stemming*

Hasil Proses Sebelumnya (<i>Normalization</i>)	Hasil Proses <i>Stemming</i>
[pokoknya, ini, aplikasi, sangat, membantu]	[pokok, ini, aplikasi, sangat, bantu]
[sangat, bagus, sekali]	[sangat, bagus, sekali]
[kenapa, ya, kalau, gak, buka, aplikasi, kalender, balinya, puja, trisandia, nya, gak, mau, padahal, dulu, baik, saja, sudah, mengikuti, cara, pengaturan, yang, di, sarankan, juga, tetep, gak, mau]	[kenapa, ya, kalau, gak, buka, aplikasi, kalender, bali, puja, trisandia, nya, gak, mau, padahal, dulu, baik, saja, sudah, ikut, cara, atur, yang, di, saran, juga, tetep, gak, mau]
[terima kasih]	[terima kasih]
[non, muslim, kalender, sudah, kuhapus]	[non, muslim, kalender, sudah, hapus]

4.2.6 *Stopword Removal*

Tahap *stopword removal* akan melakukan penghapusan kata-kata yang kurang bermakna, kurang penting dan tidak dibutuhkan, karena dianggap sebagai kata yang kurang informatif. Setelah menghilangkan *stopword* maka diakhir proses ini akan didapatkan kata-kata yang lebih bermakna dan relevan untuk analisis teks. Implementasi *source code* untuk proses *stopword removal* dapat dilihat pada gambar 4.13.

```

from nltk.corpus import stopwords
import nltk
nltk.download('stopwords')
list_stopwords = set(stopwords.words('indonesian'))

def stopwords_removal(row):
    text = row['content']
    stop = set(list_stopwords)
    # Menambahkan kata ke dalam set stopword
    stop.update(['nya', 'ber', 'an', 'nge', 'nih', 'eh', 'deh', 'sih',
                'ya', 'iya', 'haha',
                'sumatera', 'selatan', 'sulawesi', 'utara', 'lamongan'])

    # Menghapus stopwords dari teks
    filtered_text = [word for word in text if word not in stop]
    return filtered_text

# Melakukan stopword removal pada ulasan
new_df['content'] = new_df.apply(stopwords_removal, axis=1)

```

Gambar 4. 13 Source Code Stopword Removal

Pada gambar 4.13, proses *stopword removal* menggunakan pustaka NLTK dengan mengimpor *stopwords* untuk mengakses daftar *stopword* bahasa Indonesia. Setelah itu, daftar *stopword* diunduh menggunakan `nltk.download('stopwords')`. Beberapa kata yang termasuk dalam *stopword* tersebut yaitu "yang", "sebuah", "tidak", dan lain sebagainya. Langkah selanjutnya membuat fungsi *stopwords_removal* yang akan diterapkan pada setiap baris teks dalam kolom *'content'* *DataFrame new_df*. Fungsi ini menghilangkan kata-kata *stopword* dari teks, dengan menambahkan beberapa kata tambahan yang dianggap tidak relevan seperti 'nya', 'ber', 'an', dan lainnya ke dalam set *stopword*.

Proses *stopword removal* diimplementasikan dengan menggunakan list comprehension, di mana setiap kata dalam teks yang tidak termasuk dalam set *stopword* akan disaring dan dihasilkan teks yang telah dibersihkan dari kata-kata yang tidak penting. Hasil setelah proses *stopword removal*, dapat dilihat pada tabel 4.9 berikut.

Tabel 4. 9 Contoh Hasil *Stopword Removal*

Hasil Proses Sebelumnya (<i>Stemming</i>)	Hasil Proses <i>Stopword Removal</i>
[pokok, ini, aplikasi, sangat, bantu]	[pokok, aplikasi, bantu]
[sangat, bagus, sekali]	[bagus]
[kenapa, ya, kalau, gak, buka, aplikasi, kalender, bali, puja, trisandia, nya, gak, mau, padahal, dulu, baik, saja, sudah, ikut, cara, atur, yang, di, saran, juga, tetep, gak, mau]	['gak', 'buka', 'aplikasi', 'kalender', 'bali', 'puja', 'trisandia', 'gak', 'ikut', 'atur', 'saran', 'tetep', 'gak']
[terima kasih]	[terima kasih]
[non, muslim, kalender, sudah, hapus]	[non, muslim, kalender, hapus]

4.2.7 *Cleaning*

Cleaning pada tahap akhir *pre-processing* ini bertujuan untuk menghapus semua baris data yang memuat list kosong '[']' akibat proses *stopword removal*. List kosong merupakan salah satu *noise* dari data sehingga perlu dihilangkan dari dataset. Dengan *cleaning* tahap akhir ini diharapkan dapat meningkatkan kualitas data dan menghasilkan akurasi klasifikasi yang tinggi. Implementasi *source code* untuk proses *cleaning* list kosong dapat dilihat pada gambar 4.14.

```
def remove_empty_content(df):
    # Menghapus baris dengan 'content' yang berisi list kosong ([])
    df = df[df['content'].apply(lambda x: x != [])]
    return df

# Menghapus content dengan list kosong
new_df = remove_empty_content(new_df)
```

Gambar 4. 14 *Source Code Cleaning List Kosong*

Proses *cleaning* list kosong pada gambar 4.14 dilakukan dengan menggunakan fungsi *remove_empty_content*. Dalam implementasinya, baris-baris

yang memiliki *'content'* berupa list atau array kosong di *DataFrame 'df'* dihapus menggunakan fungsi lambda yang menguji setiap baris untuk memastikan bahwa nilai dalam kolom *'content'* tidak setara dengan daftar kosong. Hasil pembersihan kemudian disimpan kembali ke dalam *DataFrame 'df'*, dan variabel *'new_df'* diperbarui dengan hasil pemanggilan fungsi tersebut.

4.3 Implementasi Pembagian Rentang Waktu Data

Setelah mendapatkan Pembagian rentang waktu data ini dilakukan karena ada indikasi ulasan negatif yang lebih tinggi setelah pembaruan aplikasi di masa pandemi covid. Dalam hal ini, data yang termasuk dalam rentang waktu data sebelum covid merupakan ulasan yang diunggah dari tanggal 1 Agustus 2013 hingga 29 Februari 2020 sedangkan data yang termasuk dalam rentang waktu data setelah covid merupakan ulasan yang diunggah dari tanggal 1 Maret 2020 hingga 28 Juni 2023. Implementasi *source code* untuk proses pembagian rentang waktu data dapat dilihat pada gambar 4.15.

```
# Memilah data berdasarkan tanggal (sebelum covid)
start_date = '2013-08-01'
end_date = '2020-03-01'

# Menyimpan hasil pemilahan ke dalam df
df_before_covid = new_df[(new_df['at'] >= start_date) & (new_df['at'] <= end_date)]

# Memilah data berdasarkan tanggal (setelah covid)
start_date = '2020-03-01'
end_date = '2023-06-29'


# Menyimpan hasil pemilahan ke dalam df
df_after_covid = new_df[(new_df['at'] >= start_date) & (new_df['at'] <= end_date)]
```

Gambar 4. 15 *Source Code* Pembagian Rentang Waktu Data

Dalam gambar 4.15, pembagian rentang waktu berdasarkan tanggal, dengan dua periode yang dibedakan: sebelum dan setelah periode pandemi covid. Untuk data sebelum covid, rentang tanggal ditentukan mulai dari '2013-08-01' hingga

'2020-03-01'. *End_date* diatur sehari setelah tanggal 29 Februari 2020 agar data pada 29 Februari 2020 pukul 23.59 tetap masuk ke dalam rentang data sebelum covid. Hasil pemilahan disimpan dalam *DataFrame* '*df_before_covid*'. Proses ini bertujuan untuk fokus pada data sebelum munculnya pandemi.


Selanjutnya, dilakukan pemilahan data untuk periode setelah covid. Rentang tanggal untuk periode ini ditetapkan mulai dari '2020-03-01' hingga '2023-06-29'. *End_date* masih diatur sehari setelah tanggal 28 Juni 2023 agar data pada 28 Juni 2023 pukul 23.59 tetap masuk ke dalam rentang data setelah covid. Hasil pemilahan disimpan dalam *DataFrame* '*df_after_covid*'. Pemisahan ini memungkinkan analisis yang lebih terfokus terhadap data pasca munculnya pandemi. Kedua rentang waktu data memberikan gambaran perbandingan antara situasi sebelum dan setelah periode pandemi covid. Setiap *DataFrame* menyimpan entri yang relevan sesuai dengan rentang tanggal yang ditentukan. Distribusi data kedua rentang waktu data dapat dilihat pada gambar 4.16.



Gambar 4. 16 Distribusi Data Sebelum dan Setelah Pandemi Covid

Pada gambar 4.16 terlihat bahwa rentang waktu data sebelum covid memiliki presentase distribusi data yang lebih tinggi yaitu 77,3%, dibandingkan

dengan data setelah covid yang hanya memiliki presentase distribusi data sebesar 22.7% Untuk distribusi sentimen masing-masing rentang waktu data dapat dilihat pada gambar 4.17.



Gambar 4. 17 Distribusi Sentimen Data Sebelum dan Setelah Pandemi Covid

Pada gambar 4.17 terlihat dengan jelas bahwa rentang waktu data setelah covid memiliki presentase distribusi data sentimen negatif yang lebih tinggi yaitu 15.1% dibandingkan dengan data sebelum pandemi covid yang hanya memiliki presentase distribusi data sentimen negatif sebesar 7.4%. Dalam hal ini, indikasi nilai ulasan dengan sentimen negatif yang lebih tinggi untuk data setelah pandemi covid dinyatakan benar sehingga tahapan selanjutnya dilakukan dengan menggunakan 2 data yaitu sebelum dan setelah pandemi covid.

4.4 Implementasi Pembobotan Kata

Pembobotan kata merupakan proses memberi bobot pada setiap kata, dimana pada penelitian ini, teknik yang digunakan untuk pembobotan kata adalah *Term Frequency – Inverse Document Frequency* (TF-IDF). Implementasi *source code* untuk proses pembobotan kata TF-IDF dapat dilihat pada gambar 4.18.

```

!pip install scikit-learn
from sklearn.feature_extraction.text import TfidfVectorizer

# Menghitung TF-IDF menggunakan TfidfVectorizer
tfidf_vectorizer = TfidfVectorizer()
tfidf_matrix = tfidf_vectorizer.fit_transform(new_df['content'])

# DataFrame untuk menyimpan hasil TF-IDF
tfidf_df = pd.DataFrame(tfidf_matrix.toarray(), columns=tfidf_vectorizer.get_feature_names_out())

```

Gambar 4. 18 *Source Code* Pembobotan Kata

Pada gambar 4.18, dilakukan pembobotan kata dengan pustaka scikit-learn digunakan untuk menghitung TF-IDF dari teks dalam DataFrame `new\_df`. Setelah mengimpor kelas *TfidfVectorizer*, objek `tfidf\_vectorizer` dibuat untuk merepresentasikan metode tersebut. Selanjutnya, melalui metode `fit_transform`, kita menghasilkan matriks TF-IDF (`tfidf\_matrix`) dari teks dalam kolom 'content' DataFrame. Matriks TF-IDF yang diperoleh diubah menjadi DataFrame terstruktur dengan nama kolom yang berasal dari fitur-fitur unik dalam teks. Hasilnya disimpan dalam DataFrame `tfidf\_df`. Pembobotan kata dilakukan pada masing-masing dataset yaitu sebelum dan setelah pandemic covid untuk membantu mempersiapkan data teks untuk analisis dan pemodelan lebih lanjut dengan menggunakan nilai bobot TF-IDF. Hasil implementasi dari pembobotan kata dapat dilihat pada gambar 4.19 dan gambar 4.20.

```

2258, 0.7359154336639739
2258, 0.46320442570532283
2258, 0.49383209140574
2259, 1.0
2260, 1.0
2261, 1.0
2262, 1.0
2263, 1.0
2264, 0.37366862937857037
2264, 0.32378270554503724
2264, 0.2811776407656247
2264, 0.31899848210845055
2264, 0.17320009301737643
2264, 0.16191060532330184
2264, 0.6505209680531148
2264, 0.15287647923548317
2264, 0.17338356043759226
2264, 0.20467460664835196
2265, 0.5875615910443225

```

Gambar 4. 19 Contoh Pembobotan Kata Untuk Data Sebelum Covid

0, 0.70301915474866
0, 0.7111709133931727
1, 0.8854824783630904
1, 0.46467276712968564
2, 0.8021138227934596
2, 0.5971711775392903
3, 0.5314503267730086
3, 0.7747608212770696
3, 0.3424999561853156
4, 1.0
5, 1.0
6, 0.35647618054406527
6, 0.5111390247583311
6, 0.43100063707532044
6, 0.44933279418993444
6, 0.4233151033002477
6, 0.21167060329165105
7, 0.8270315272224115
7, 0.3656886752069419
7, 0.42695508640319235
8, 1.0

Gambar 4. 20 Contoh Pembobotan Kata Untuk Data Setelah Covid

Dari contoh hasil pembobotan kata tersebut, berikut merupakan kata yang sering muncul (*wordcloud*) untuk masing-masing dataset dapat dilihat pada gambar 4.21 dan gambar 4.22.



Gambar 4. 21 Wordcloud Sebelum Covid


```

from sklearn.model_selection import StratifiedKFold

# Values of n_splits to iterate over
n_splits_values = [3, 5, 7, 9]

# Dictionary to store the sets for each n_splits
data_splits = {}

for n_splits in n_splits_values:
    # Split dataset using k-fold cross-validation
    kfold = StratifiedKFold(n_splits=n_splits, shuffle=True, random_state=42)

    # Lists to store sets for the current n_splits
    X_train_sets, X_test_sets, y_train_sets, y_test_sets = [], [], [], []
    print(f"\nk-fold {n_splits}:")
    for i, (train_index, test_index) in enumerate(kfold.split(tfidf_df, new_df['sentiment'])):
        print(f"\nFold {i+1}:")
        print("Training Index:", train_index)
        print("Testing Index:", test_index)

        X_train, X_test = tfidf_df.iloc[train_index], tfidf_df.iloc[test_index]
        y_train, y_test = new_df['sentiment'].iloc[train_index], new_df['sentiment'].iloc[test_index]

        # Append the sets to the lists
        X_train_sets.append(X_train)
        X_test_sets.append(X_test)
        y_train_sets.append(y_train)
        y_test_sets.append(y_test)


    # Store the sets in the dictionary for the current n_splits
    data_splits[n_splits] = {
        'X_train': X_train_sets,
        'X_test': X_test_sets,
        'y_train': y_train_sets,
        'y_test': y_test_sets
    }

```


Gambar 4. 23 Source Code Pembagian Data

Pada Gambar 4.23, setelah mendapatkan bobot dari setiap kata menggunakan matriks TF-IDF. Tahap awal dilakukan pembagian data *training* dan data *testing* dengan menggunakan *k-Fold Cross-Validation*. Pertama, kelas `'StratifiedKFold'` diimpor dari modul `'model_selection'` scikit-learn. Objek `'kfold'` dibuat untuk mewakili k-Fold Cross-Validation dengan jumlah lipatan (`'n_splits'`) yang bervariasi: 3, 5, 7, dan 9, sesuai dengan nilai dalam `'n_splits_values'`. Pengaturan `'shuffle=True'` memastikan pengacakan data sebelum pembagian, sedangkan `'random_state=42'` digunakan untuk hasil yang konsisten. Konsisten yang di maksud adalah memastikan bahwa meskipun ada unsur acak dalam proses, hasilnya akan selalu sama jika di kode jalankan dengan parameter yang sama.

Selanjutnya, dilakukan iterasi melalui setiap lipatan dengan menggunakan perulangan `for`. Dalam setiap iterasi, indeks untuk data pelatihan (`train_index`) dan data pengujian (`test_index`) diperoleh. Data ini digunakan untuk menghasilkan subset dari matriks TF-IDF (`tfidf_df`) dan kolom target (`new_df['sentiment']`). Subset tersebut digunakan untuk melatih dan menguji model pada setiap lipatan. Pembagian data dilakukan pada dua dataset, yaitu data sebelum dan setelah pandemi covid. Untuk visualisasi pembagian data pada data sebelum dan setelah pandemi covid menggunakan nilai k yang berbeda dapat dilihat pada gambar 4.24 dan gambar 4.25.



Gambar 4. 24 Distribusi Pembagian Data Untuk Data Sebelum Pandemi Covid



Gambar 4. 25 Distribusi Pembagian Data Untuk Data Setelah Pandemi Covid

Pada gambar 4.24 dan gambar 4.25, setiap pembagian data memiliki jumlah data *training* dan data *testing* yang berbeda sesuai dengan hasil pembagian lipatannya. Hal tersebut memungkinkan adanya nilai akurasi untuk klasifikasi yang berbeda, tergantung jumlah lipatan untuk pembagian data pada proses *k-Fold Cross Validation*.

4.6 Implementasi Klasifikasi

Tahap klasifikasi dilakukan dengan menggunakan metode KNN. KNN merupakan merupakan metode klasifikasi yang mengelompokan data baru berdasarkan jarak data baru ke beberapa data atau tetangga terdekat. Nilai *k/tetangga/neighbor* yang digunakan adalah 3, 5, 7, dan 9. Klasifikasi dilakukan untuk setiap data hasil pembagian *k-Fold Cross Validation*, sehingga klasifikasi dilakukan sebanyak empat kali yaitu untuk *k-fold* 3, 5, 7, dan 9. Implementasi

source code untuk proses klasifikasi menggunakan KNN dapat dilihat pada gambar 4.26.

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score,
precision_score, recall_score, f1_score

# Values of n_neighbors
neighbor_values = [3, 5, 7, 9]
accuracy_no_tomek = []
presisi_no_tomek = []
recall_no_tomek = []
f1_score_no_tomek = []

for n_neighbors_value in neighbor_values:

    for i in range(len(data_splits[3]['X_train'])):
        X_train = data_splits[3]['X_train'][i]
        X_test = data_splits[3]['X_test'][i]
        y_train = data_splits[3]['y_train'][i]
        y_test = data_splits[3]['y_test'][i]

        # Create a KNN classifier with the current n_neighbors value
        knn_classifier = KNeighborsClassifier(n_neighbors=n_neighbors_value)

        # Train the model
        knn_classifier.fit(X_train, y_train)


        # Make predictions on the test set
        y_pred = knn_classifier.predict(X_test)

        # Evaluate the model
        conf_matrix = confusion_matrix(y_test, y_pred)
        accuracy = accuracy_score(y_test, y_pred)
        presisi = precision_score(y_test, y_pred, average='weighted')
        recall = recall_score(y_test, y_pred, average='weighted')
        f1 = f1_score(y_test, y_pred, average='weighted')
        class_report = classification_report(y_test, y_pred)
```


Gambar 4. 26 *Source Code* Klasifikasi KNN

Dalam potongan kode pada gambar 4.26, digunakan modul *sklearn.neighbors* untuk mengimplementasikan model *K-Nearest Neighbors* (KNN). Kode ini dirancang untuk melakukan evaluasi performa model KNN dengan variasi nilai *k/tetangga/n_neighbors* (3, 5, 7, dan 9) menggunakan beberapa jenis model evaluasi. Pada setiap iterasi melalui nilai *n_neighbors*, juga dilakukan iterasi melalui dataset yang telah dibagi sebelumnya dalam lipatan *k-fold* yaitu 3, 5,


7 dan 9 (gambar 4.26 mewakili penggunaan $k=3$). Setiap iterasi melibatkan pemisahan dataset menjadi bagian latih dan uji. Model KNN kemudian dibuat dan dilatih pada dataset latih, diikuti oleh prediksi pada dataset uji. Evaluasi model melibatkan perhitungan *confusion matrix*, akurasi, presisi, recall, dan *f1 score* menggunakan fungsi dari modul *sklearn.metrics*. Hasil evaluasi ini kemudian dicatat untuk setiap nilai *n_neighbors*, memberikan pemahaman tentang kinerja model KNN pada dataset tertentu dengan variasi parameter *n_neighbors*. Untuk perbandingan hasil evaluasi KNN pada data sebelum dan setelah pandemi covid menggunakan nilai *k-fold* yang berbeda dapat dilihat pada gambar 4.27 hingga gambar 4.34.




Gambar 4. 27 Perbandingan Akurasi Pada Data Sebelum Pandemi Covid



Gambar 4. 28 Perbandingan Presisi Pada Data Sebelum Pandemi Covid




Gambar 4. 29 Perbandingan *Recall* Pada Data Sebelum Pandemi Covid




Gambar 4. 30 Perbandingan *F1 Score* Pada Data Sebelum Pandemi Covid


Berdasarkan hasil evaluasi klasifikasi KNN data sebelum pandemi covid pada gambar 4.27 hingga gambar 4.30 dapat diketahui bahwa nilai akurasi tertinggi untuk data sebelum pandemi covid terdapat pada $n_neighbor$ 5 dengan $k-fold$ 9 yang mendapatkan akurasi sebesar 93.7% dengan presisi 92.5%, *recall* 93.7% serta *f1-score* 92.3%.




Gambar 4. 31 Perbandingan Akurasi Pada Data Setelah Pandemi Covid



Gambar 4. 32 Perbandingan Presisi Pada Data Setelah Pandemi Covid



Gambar 4. 33 Perbandingan *Recall* Pada Data Setelah Pandemi Covid



Gambar 4. 34 Perbandingan *F1 Score* Pada Data Setelah Pandemi Covid

Berdasarkan hasil evaluasi klasifikasi KNN data setelah pandemi covid pada gambar 4.31 hingga gambar 4.34 dapat diketahui bahwa nilai akurasi tertinggi

untuk data setelah pandemi covid terdapat pada $n_neighbor$ 3 dan 9 dengan k -fold 3 yang mendapatkan akurasi sebesar 86.0% dengan presisi 83.7%, *recall* 86.0% serta *f1-score* 83.9%.

4.7 Implementasi *Balancing* Data

Pada tahap ini *balancing* data dilakukan dengan *Tomek Links undersampling*. *Tomek Links* menyeimbangkan data *training* dengan mengurangi jumlah sampel mayoritas yang posisinya berdekatan dengan sampel minoritas yang berada di sekitarnya. Implementasi *source code* untuk proses *balancing* data menggunakan *Tomek Links* dapat dilihat pada gambar 4.35.

```
from imblearn.under_sampling import TomekLinks


for i in range(len(data_splits[3]['X_train'])):
    X_train = data_splits[3]['X_train'][i]
    X_test = data_splits[3]['X_test'][i]
    y_train = data_splits[3]['y_train'][i]
    y_test = data_splits[3]['y_test'][i]

# Menerapkan Tomek links untuk menyeimbangkan data latih
tomek_links = TomekLinks()
X_train_balanced, y_train_balanced = tomek_links.fit_resample(X_train, y_train)
```


Gambar 4. 35 *Source Code Tomek Links*

Dalam kode pada gambar 4.35 tersebut, penggunaan modul `imblearn.under_sampling` dengan kelas `TomekLinks` digunakan untuk mengatasi ketidakseimbangan kelas pada data latih (*training*). Iterasi dilakukan melalui *data splits* yang telah dibagi sebelumnya menggunakan lipatan atau k -fold yaitu 3, 5, 7 dan 9 (gambar mewakili penggunaan $k=3$). Pada setiap iterasi, dataset latih dan uji sesuai lipatan diambil kemudian metode *Tomek Links* diterapkan menggunakan *fit_resample* pada dataset latih. Penggunaan metode *Tomek Links* akan menghasilkan versi dataset latih yang telah disesuaikan untuk mengatasi ketidakseimbangan kelas. Proses ini dilakukan untuk setiap *fold* atau iterasi,


sehingga setelah perulangan selesai, didapatkan dataset latih yang telah diseimbangkan untuk setiap *fold*. Dengan menggunakan metode *balancing* ini, diharapkan bahwa perbandingan jumlah sampel antara kelas mayoritas dan minoritas menjadi lebih seimbang, sehingga dapat meningkatkan kualitas pembelajaran model terutama pada kelas minoritas. Perbandingan distribusi data sebelum dan setelah menggunakan *Tomek Links* pada data sebelum dan setelah pandemi covid dapat dilihat pada gambar 4.36 hingga 4.43.




Gambar 4. 36 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold* 3



Gambar 4. 37 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold* 5




Gambar 4. 38 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold* 7




Gambar 4. 39 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold* 9


Berdasarkan gambar 4.36 hingga gambar 4.39 dapat dilihat bahwa terjadi penurunan jumlah data mayoritas yakni yang berlabel positif dalam jumlah yang tidak terlalu signifikan. Untuk data sebelum pandemi covid, *Tomek Links* pada data *k-fold* 3, 5, 7, dan 9, masing-masing menurunkan data mayoritas 0.7%, 0.8%, 0.7% dan 0.6%. Presentase penurunan data terbesar akibat penggunaan *Tomek Links* ada pada data *k-fold* 5 yaitu sebesar 0.8%.




Gambar 4. 40 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold 3*



Gambar 4. 41 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold 5*



Gambar 4. 42 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold 7*




Gambar 4. 43 Perbandingan Distribusi Data Hasil *Tomek Links* Pada *k-fold* 9

Berdasarkan gambar 4.40 hingga gambar 4.43 dapat dilihat bahwa terjadi penurunan jumlah data mayoritas yakni yang berlabel positif. Untuk data setelah pandemi covid, *Tomek Links* pada data *k-fold* 3, 5, 7, dan 9, masing-masing menurunkan data mayoritas 1.5%, 1.2%, 1.2% dan 1.1%. Presentase penurunan data terbesar akibat penggunaan *Tomek Links* ada pada data *k-fold* 3 yaitu sebesar 1.5%. Jika dibandingkan dengan penurunan pada data sebelum pandemi covid, *Tomek Links* pada data setelah pandemi covid menurunkan data mayoritas dalam jumlah yang lebih tinggi. Proses *balancing* data ini diharapkan dapat membantu proses *train model* untuk mendapatkan akurasi yang lebih akurat.


4.8 Implementasi Klasifikasi menggunakan *Balanced Dataset*

Setelah klasifikasi awal pada data yang tidak seimbang, langkah selanjutnya adalah melakukan klasifikasi pada dataset yang telah diseimbangkan (*balanced dataset*). Proses klasifikasi masih menggunakan *source code* yang sama dengan gambar 4.26, namun data berlabel positif yang digunakan adalah data berlabel positif hasil *balancing* data menggunakan *Tomek Links*. Untuk perbandingan hasil evaluasi KNN dan *balanced dataset* pada data sebelum dan setelah pandemi covid


menggunakan nilai k -fold yang berbeda dapat dilihat pada gambar 4.27 hingga gambar 4.34.




Gambar 4. 44 Perbandingan Akurasi KNN dan *Tomek Links* Pada Data Sebelum Pandemi Covid



Gambar 4. 45 Perbandingan Presisi KNN dan *Tomek Links* Pada Data Sebelum Pandemi Covid




Gambar 4. 46 Perbandingan *Recall* KNN dan *Tomek Links* Pada Data Sebelum Pandemi Covid




Gambar 4. 47 Perbandingan *F1 Score* KNN dan *Tomek Links* Pada Data Sebelum Pandemi Covid


Berdasarkan hasil evaluasi klasifikasi KNN dan *balanced dataset* oleh *Tomek Links* untuk data sebelum pandemi covid pada gambar 4.44 hingga gambar 4.47 dapat diketahui bahwa nilai akurasi tertinggi untuk data sebelum pandemi covid terdapat pada $n_neighbor$ 3 dengan $k-fold$ 9 yang mendapatkan akurasi sebesar 94.3% dengan presisi 93.6%, *recall* 94.3% serta *f1-score* 92.0%.




Gambar 4. 48 Perbandingan Akurasi KNN dan *Tomek Links* Pada Data Setelah Pandemi Covid



Gambar 4. 49 Perbandingan Presisi KNN dan *Tomek Links* Pada Data Setelah Pandemi Covid



Gambar 4. 50 Perbandingan *Recall* KNN dan *Tomek Links* Pada Data Setelah Pandemi Covid



Gambar 4. 51 Perbandingan *F1 Score* KNN dan *Tomek Links* Pada Data Setelah Pandemi Covid

Berdasarkan hasil evaluasi klasifikasi KNN dan *balanced dataset* oleh *Tomek Links* untuk data setelah pandemi covid pada gambar 4.48 hingga gambar 4.51 dapat diketahui bahwa nilai akurasi tertinggi untuk data setelah pandemi covid terdapat pada $n_neighbor$ 9 dengan $k-fold$ 3 yang mendapatkan akurasi sebesar 87.2% dengan presisi 85.6%, *recall* 87.2% serta *f1-score* 83.9%.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Pada penelitian ini, data ulasan aplikasi Kalender Bali dibagi berdasarkan periode sebelum dan setelah covid-19. Analisis sentimen telah dilakukan dengan menggunakan metode klasifikasi KNN dengan beberapa parameter k yaitu 3, 5, 7 dan 9 serta menerapkan metode *balancing data* menggunakan teknik *Tomek Links*. Pembagian data menggunakan *k-Fold Cross Validation* sendiri menggunakan beberapa parameter k yang berbeda yaitu 3, 5, 7, dan 9 serta *random state* yaitu 42. Dari penelitian tersebut menghasilkan :

1. Hasil analisis untuk data ulasan sebelum pandemi covid diperoleh :
 - a. Penelitian menggunakan KNN menghasilkan akurasi tertinggi sebesar 93.7% menggunakan nilai $k = 5$ untuk KNN dan nilai $k = 9$ untuk *k-Fold Cross Validation*
 - b. Penelitian menggunakan KNN dan *Tomek Links* menghasilkan akurasi tertinggi sebesar 94.3% menggunakan nilai $k = 3$ untuk KNN dan nilai $k = 9$ untuk *k-Fold Cross Validation*
2. Hasil analisis untuk data ulasan setelah pandemi covid diperoleh :
 - a. Penelitian menggunakan KNN menghasilkan akurasi tertinggi sebesar 86.0% menggunakan nilai $k = 9$ untuk KNN dan nilai $k = 3$ untuk *k-Fold Cross Validation*
 - b. Penelitian menggunakan KNN dan *Tomek Links* menghasilkan akurasi tertinggi sebesar 87.2% menggunakan nilai $k = 9$ untuk KNN dan nilai $k = 3$ untuk *k-Fold Cross Validation*

Dari hasil penelitian tersebut dapat dilihat adanya peningkatan akurasi pada saat mengkombinasikan algoritma KNN dengan algoritma *Tomek Links*, dimana pada data sebelum pandemi covid akurasi meningkat sebesar 0.6% sedangkan pada data sesudah pandemi covid akurasi meningkat sebesar 1.2%. Dapat disimpulkan bahwa penggunaan algoritma *Tomek Links* untuk menangani data tidak seimbang pada penelitian ini tepat karena dapat menghasilkan akurasi yang lebih optimal pada data sebelum pandemi covid maupun data sesudah pandemi covid.

5.2. Saran

Berdasarkan penelitian yang telah dilakukan, saran yang diberikan dari hasil penelitian ini, yaitu:

1. Menambahkan *mapping* persebaran jumlah data pada proses *labeling*.
2. Penelitian selanjutnya diharapkan dapat dikembangkan dengan pembuatan GUI (*Graphical User Interface*) untuk mempermudah visualisasi hasil.
3. Menambahkan kata dalam list *stopword removal* pada tahap *preprocessing* data untuk menekan jumlah variasi kata.
4. Menerapkan metode *supervised learning* lainnya seperti SVM (*Support Vector Machine*), *Naive Bayes* atau *Random Forest* untuk mengetahui akurasi pada metode tersebut.
5. Menerapkan metode *balancing* lainnya seperti SMOTE (*Synthetic Minority Over-sampling Technique*), ADASYN (*Adaptive Synthetic Sampling*) atau ROS (*Random Over Sampling*) yang dapat menaikkan jumlah kelas minoritas dengan menghasilkan sampel sintetis untuk kelas minoritas sehingga didapatkan data yang seimbang.

DAFTAR PUSTAKA

- Alhaqq, R.I., Putra, I.M.K. and Ruldeviyani, Y. (2022) 'Analisis Sentimen terhadap Penggunaan Aplikasi MySAPK BKN di Google Play Store', *Jurnal Nasional Teknik Elektro dan Teknologi Informasi*, 11(2), pp. 105–113. Available at: <https://doi.org/10.22146/jnteti.v11i2.3528>.
- Alitmd (2021) *Kalender Bali*. Available at: <https://play.google.com/store/apps/details?id=com.alitmd.kalenderbali&hl=id&gl=US> (Accessed: 23 May 2023).
- Aprilianti, N.M.D. *et al.* (2023) 'Analisis Perbandingan Algoritma KNN, Gaussian Naive Bayes, Random Forest Untuk Data Tidak Seimbang Dan Data Yang Diseimbangkan Dengan Metode Tomek Link Undersampling Pada Dataset LCMS Tanaman Keladi Tikus', 13(1), pp. 156–160.
- Astuti, P. and Nuris, N. (2022) 'Penerapan Algoritma KNN Pada Analisis Sentimen Review Aplikasi Peduli Lindungi', *Computer Science (CO-SCIENCE)*, 2(2), pp. 137–142. Available at: <https://doi.org/10.31294/coscience.v2i2.1258>.
- Badan Pusat Statistik (2019) *Proporsi Individu Yang Menggunakan Internet Menurut Provinsi*. Available at: <https://www.bps.go.id/indicator/27/1225/1/proporsi-individu-yang-menggunakan-internet-menurut-provinsi.html> (Accessed: 28 November 2023).
- Barus, S.G. (2022) 'Klasifikasi Sentimen Data Tidak Seimbang Menggunakan Algoritma Smote Dan K-Nearest Neighbor Pada Ulasan Pengguna Aplikasi Pedulilindungi', *Senamika*, pp. 162–173.
- Cholil, S.R. *et al.* (2021) 'IJCIT (Indonesian Journal on Computer and Information Technology) Implementasi Algoritma Klasifikasi K-Nearest Neighbor (KNN) Untuk Klasifikasi Seleksi Penerima Beasiswa', *IJCIT (Indonesian Journal on Computer and Information Technology)*, 6(2), pp. 118–127.
- Denes, I.M. *et al.* (1997) *Kamus Bahasa Indonesia-Bali A-K*. Jakarta: Pusat Pembinaan dan Pengembangan Bahasa.
- Dewi, I.A.M.C., Dharmendra, I.K. and Setiasih, N.W. (2023) 'Analisis Sentimen Review Aplikasi Satu Sehat Mobile Menggunakan Model Sampling Tomek Links', pp. 2–8. Available at: <https://jurnal.undhirabali.ac.id/index.php/jutik/article/view/2644/3309>.
- Erawan, L. (2015) 'Pedoman Praktikum Standar Web', *Pemrograman Web*, pp. 1–109.

- Iwandini, I., Triayudi, A. and Soepriyono, G. (2023) 'Analisa Sentimen Pengguna Transportasi Jakarta Terhadap Transjakarta Menggunakan Metode Naives Bayes dan K-Nearest Neighbor', *Journal of Information System Research (JOSH)*, 4(2), pp. 543–550. Available at: <https://doi.org/10.47065/josh.v4i2.2937>.
- Liu, B. (2015) *Sentiment Analysis: Mining Opinions, Sentiments, and Emotions*. Available at: <https://doi.org/10.1017/CBO9781139084789>.
- Mitchell, R. (2018) *Ryan Mitchell Web Scraping with Python*. Available at: www.allitebooks.com.
- Mondal, S. *et al.* (2023) 'Machine Learning-based maternal health risk prediction model for IoMT framework', *International Journal of Experimental Research and Review*, 32, pp. 145–159. Available at: <https://doi.org/10.52756/ijerr.2023.v32.012>.
- Purbo, O.W. (2019) *Text Mining, Analisis Medsos, Kekuatan Brand dan Intelijen di Internet*. ANDI.
- Python (2016) *Sastrawi, Python*. Available at: <https://pypi.org/project/Sastrawi/> (Accessed: 27 November 2023).
- Python (2023) *Google-Play-Scraper, Python*. Available at: <https://pypi.org/project/google-play-scraper/> (Accessed: 27 November 2023).
- Supono, R.A. and Suprayogi, M.A. (2021) 'Perbandingan Metode TF-Abs dan TF-IDF Pada Klasifikasi Teks Helpdesk Menggunakan K-Nearest Neighbor', *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 5(5), pp. 911–918. Available at: <https://doi.org/10.29207/resti.v5i5.3403>.
- Utami, H. (2022) 'Analisis Sentimen dari Aplikasi Shopee Indonesia Menggunakan Metode Recurrent Neural Network', *Indonesian Journal of Applied Statistics*, 5(1), p. 31. Available at: <https://doi.org/10.13057/ijas.v5i1.56825>.
- Veluchamy, A. *et al.* (2018) 'Comparative Study cobagantiii of Sentiment Analysis with Product Reviews Using Machine Learning and Lexicon-Based Approaches', *SMU Data Science Review*, 1(4), pp. 1–22. Available at: <https://scholar.smu.edu/cgi/viewcontent.cgi?article=1051&context=datasciencereview>.
- Wahyudi, R. and Kusumawardana, G. (2021) 'Analisis Sentimen pada Aplikasi Grab di Google Play Store Menggunakan Support Vector Machine', *Jurnal Informatika*, 8(2), pp. 200–207. Available at: <https://doi.org/10.31294/ji.v8i2.9681>.

- Westergaard, D. *et al.* (2018) “A Comprehensive and Quantitative Comparison of Text-Mining in 15 Million Full-Text Articles Versus Their Corresponding Abstracts,’ *PLoS Comput Biol*, 14(2), pp. 1–16. Available at: <https://doi.org/10.1371/journal.pcbi.1005962>.
- Wijanarto, W. and Brilianti, S.P. (2020) ‘Peningkatan Performa Analisis Sentimen Dengan Resampling dan Hyperparameter pada Ulasan Aplikasi BNI Mobile’, *Jurnal Eksplora Informatika*, 9(2), pp. 140–153. Available at: <https://doi.org/10.30864/eksplora.v9i2.333>.